AKADEMIA TECHNICZNO-INFORMATYCZNA W NAUKACH STOSOWANYCH

Wydział Informatyki

Artur Jaworski

Analiza wydajności wczytywania oraz walidacji dużych plików CSV i czasu ich przetwarzania w języku Java.

Praca: magisterska
Kierunek: Informatyka
Specjalność: Programowanie
Nr albumu: 7896

Praca wykonana pod kierunkiem:
dr hab. Grzegorz Kosior

Wrocław 2025

Spis treści

1. Wstęp

Powszechnym problemem w systemach informatycznych jest przesyłania danych pomiędzy aplikacjami. Jest kilka sposobów na rozwiązanie tego dylematu. Jedną z metod jest użycie plików o określonej strukturze tj. plików w formacie *CSV*. Jak podają Mayur Ramgir oraz Nick Samoylov „*Comma Separated Values* (*CSV*) to idealna metoda przechowywania danych w formie tabelarycznej. Pliki *CSV* można łatwo przenosić do i z kilku narzędzi do przetwarzania danych, takich jak *Microsoft Excel*. Jest prosty i idealny do szybkiego transferu w wielu środowiskach.”[1].

Używanie takich plików wiąże się jednak z pewnymi ograniczeniami:

- konieczność sprawdzania formatu danych.
- konieczność walidowania pól.
- konieczność wczytywania plików do pamięci – co może prowadzić do jej przepełnienia.

Tu rodzi się pytania, jaki jest najszybszy sposób na wczytanie oraz walidowanie plików *CSV* z wykorzystaniem języka programowania *Java* w wersji 24[2].

W tej pracy zostały sprawdzone 5 różnych sposobów na wczytywanie danych z plików, z wykorzystaniem:

- *BufferedReader*
- *CSVReader*
- *FileReader*
- *Files.lines()*
- *Scanner*

Cztery pierwsze odnoszą się do biblioteki standardowej języka *Java*, natomiast ostatnia pozycja pochodzi z biblioteki *opencsv*. Dodatkowo każda z metod zostanie sprawdzona w dwóch przypadkach tj. z walidacją przeprowadzaną w trakcie wczytywania kolejnych linii z pliku oraz z walidacją przeprowadzaną po wczytaniu całego pliku do pamięci.

---

1 M. Ramgir i N. Samoylov, *Java 9 High Performance,* Wyd. Packt, Birmingham 2017.
2 Na czas pisania tej pracy najnowszą wersja języka Java w wersji LTS była właśnie wersja 24.

1.1. Cel pracy

Celem pracy było sprawdzenie wydajności kilku klas do wczytywania plików w formacie *CSV*. Wybrane klasy to *BufferedReader*, *CSVReader, FileReader, Scanner* oraz metoda statyczna *lines*() w klasie *Files*. Wszystkie te sposoby wczytywania plików zostały przetestowane w dwóch przypadkach: z walidacją podczas wczytywania kolnych linii z pliku oraz z walidacją po wczytaniu całej treści dokumentu tekstowego.

W każdym z przypadków walidacja była niezmienna i odnosiła się zarówno do ilości pól, jak i ich typów oraz unikalności danych.

Danych testowe były podzielone na 2 sekcje: dane podstawowe oraz dane rozliczeniowe. W danych podstawowych znajdowało się:

- 7 pól typu *String* w tym klucz główny,
- 3 pola typu *Integer*,
- 3 pola typu *Data*,
- 3 pola typu *Boolean*,
- 3 pola typu *Enum*.

Natomiast w danych rozliczeniowych znajdowało się:

- 1 pole typu *String* będące kluczem obcym,
- 3 pola typu *Integer*,
- 1 pole typu *Enum*,
- 2 pola typu *BigDecimal*.

Klucz złożony obejmował pola typu *String*, 3 pola typu *Integer* oraz pola typu *Enum*.

1.2. Motywacja podjęcia tematu

Temat został wybrany z powodów ciekawości autora do najszybszego podejścia do wczytywania oraz walidacji plików *CSV*. Autor w przeszłości zajmował się w pracy zarobkowej tematem optymalizacji procesów między innymi rzeczonego wczytywania plików. Natomiast w większej części skupiał się na zbędnych operacjach i uproszczeniach systemów, a nie samym wczytywaniu per se.

Wyniki badań przeprowadzonych w pracy mogą podnieść jakość kodu oraz jego wydajność w znaczącym stopniu, co przełoży się na skrócenie czasu oczekiwania na przetwarzanie danych. Wiąże się to również z obniżenie kosztów serwerów aplikacji, a także pośrednio zmniejszenia emisji gazów cieplarnianych, tak ważnym czynniku dzisiejszego, jaki i przyszłego świata.

1.3. Pytania badawcze

Celem badań była odpowiedź na następujące pytania:

- Jaki jest najszybszy sposób na wczytanie i przetwarzanie dużych plików *CSV* spośród testowanych algorytmów?
- Jaki sposób wczytanie i przetwarzanie dużych plików *CSV* zużywa najmniej pamięci spośród testowanych algorytmów?
- Czy moment wykonywania walidacji wpływa na czas oraz pamięć potrzebną do wykonania zadania?

Hipotezy:

Teoretycznie najszybszym sposobem przetwarzania plików, powinien okazać się *BufferedReader* oraz przetwarzanie strumieniowe z wykorzystaniem *Files.lines*. Z drugiej strony najmniej wydajny powinno być wykorzystanie klasy *Scanner*. Pamięć powinna być na podobnym poziomie, jednak *Files.lines* ze względu na swoją charakterystykę będzie wykorzystywać mniej pamięci operacyjnej.

Z dwóch grup algorytmów z walidacją podczas wczytywania oraz z walidacją po wczytaniu lepszą powinna okazać się pierwsza z grup zarówno pod względem czasu jak i zużytej pamięci.

2. Metodologia

Badania zostały przeprowadzane na platformie testowej wyposażoną w:

- procesor *AMD Ryzen 7 3700X* – 8 rdzeni, 16 wątków, 3,60 GHz
- 32 GB RAM, 3200MHz
- *Chipset X570*
- Dysk *SSD* 512 GB połączony interfejsem *PCIe NVMe 3.0 x4*, o deklarowanym odczycie 3350 MB/s
- *Windows 11* w wersji 24H2, z kompilacji 26100.4652
- *JAVA 24* z dystrybucji *Oracle* 24.0.1, z budowania 24.0.1+9-30

Dla ograniczenia wpływu zapełniania pamięci operacyjnej program uruchamiany w *Java'ie* miał nałożony limit 16GB RAM, poprzez ustawienie odpowiadającej flagi *-Xmx16g.*

Testy były przeprowadzane przy minimalnym zużyciu zasobów komputera. Testy kilkukrotnie wykonywały wczytanie oraz walidację dla każdego z testowanych algorytmów, oraz dla kilku wielkości plików *CSV.*

Testowanych rozwiązań było łącznie 10 podzielonych na 2 grupy:

- Grupa 1. - Walidacja podczas wczytywania plików *CSV*:
  BufferedReader, *CSVReader*, *FileReader*, *Files.lines*, *Scanner.*
- Grupa 2. - Walidacja po wczytaniu całego pliku do programu:
  BufferedReader, *CSVReader*, *FileReader*, *Files.lines*, *Scanner.*

Ze wszystkich wywołań została wyciągnięta średnia arytmetyczna, wariancja oraz została potwierdzona statystycznie hipoteza, mówiąca o tym, że dane mają rozkład normalny.

Testy zostały podzielone na 2 grupy:

Pierwsza – testy automatyczne – wykonywana w samym programie oraz druga – testy manualne – wykonywana za pomocą narzędzia *Profiler* z programu *IntelliJ IDEA* w wersji 2025.1.2 dostarczanego przez firmę *JetBrains*. Oba testy wykonywały pomiar czasu jak i zużycia pamięci.

Testy czasu wykonania przeprowadzane w samym programie wykorzystywały metodę *currentMiliseconds()* z klasy *Thread*. Po wywołaniu każdego algorytmu zapamiętywana jest ilość elementów poszczególnych zbiorów danych oraz ilość zwróconych błędów. Po każdym teście wątek był wstrzymany na 5 sekund. W badaniach uwzględniony został tylko czas pracy algorytmu bez zbierania wyników oraz czyszczenia pamięci.

Test pamięci mierzył różnicę zużycia pamięci bezpośrednio po wykonaniu zadania i przed jego wykonaniem. Aby tego dokonać pobierana jest instancja *MemoryMXBean* za pomocą fabryki *ManagementFactory.getMemoryMXBean()*. Następnie pobierana jest klasa *MemoryUsage* za pomocą *getHeapMemoryUsage()*. Wartość zużywanej akuratnie pamięci można pobrać za pomocą metody *getHeapMemoryUsage()*.

Przed wykonaniem każdego kolejnego testu, wywoływane było czyszczenie pamięci za pomocą metody statycznej *gc()* z klasy *System*. Dodatkowo został wstrzymany wątek na 5 sekund, wywołując metodę statyczną *sleep(5000)* z klasy *Thread*, aby zminimalizować wpływ *Garbage Collector'a* oraz długotrwałego obciążenia komponentów komputera na wyniki obserwacji.

Testy przeprowadzane przy użyciu *Profiler'a* w narzędziu *IntelliJ IEAD* były wykonywane pojedynczo dla każdego wywołania i ręcznie zbierano dane. Po wykonaniu programu została pobrana wartość całkowitej zarezerwowanej pamięci przez poszczególne algorytmy, jak i czas ich wykonywania. Narzędzie daje możliwość pobrania czasu przetwarzania konkretnej metody, stąd można pobrać czas trwania samej walidacji, bądź samego wczytania i parsowania pliku CSV.

Podobna możliwość istniała dla czasu wymaganego przez procesor, jednak nie została ona wykorzystywana.

2.1. Plik CSV

Pliki, jakie zostały użyte do badań, zostały wygenerowane osobnym programem opisanym dokładniej w punkcie 2.2

Dane w plikach odnoszą się dziedzinowo do zakładów energetycznych oraz ich danych rozliczeniowych.
Plik podzielony został na 2 sekcje:

- Dane podstawowe,
- Dane rozliczeniowe.

Dane podstawowe odnoszą się do informacji o samych zakładach produkcyjnych. Dane te posiadają klucz głównych będący 29 znakowym identyfikatorem każdego przedsiębiorstwa. Kolejne dane odnoszą się do danych adresowych oraz danych związanych z działaniem zakładu. Wszystkie dane generowane na cale badań nie są rzeczywiste. Łącznie w danych podstawowych jest 19 kolumn z danymi i 1 kolumna określająca sekcję. Jest to pierwsza kolumna, której wartość zawsze jest równa „M”.

Dane rozliczeniowe są to dane odnoszące się do danych podstawowych. Do tego służy klucz obcy będący identyfikatorem przedsiębiorstwa z sekcji pierwszej. Dane zawierają ilość wyprodukowanej energii w jednostkach pracy oraz kwotę należną do zapłaty za produkcję. Dane te zawierają ponadto informacje o roku, miesiącu, dniu rozliczenia oraz typ raportu. Dzień nie jest polem obowiązkowym.

Dla każdego identyfikatora zakładu możliwe jest wiele wpisów w sekcji rozliczeniowej. Natomiast niemożliwe jest zduplikowanie danych rozliczeniowych dla takiego samego identyfikatora zakładu, typu raportu i roku, miesiąca oraz dnia. Mówiąc krótko – jest to klucz złożony dla sekcji rozliczeniowej.

Łącznie w danych rozliczeniowych jest 7 kolumn z danymi oraz podobnie jest w przypadku danych podstawowych 1 – pierwsza kolumna określająca sekcję w pliku. Wartość pierwszej kolumny w tej sekcji zawsze przyjmuje wartość „A”.

Dane w sekcjach zostały dobrane tak, aby wykorzystać najpopularniejszą cześć dostępnych typów danych.

Typy występujące w pierwszej sekcji to:

- 7 pól typu *String* w tym klucz główny,

- 3 pola typu *Integer*,
- 3 pola typu *Data*,
- 3 pola typu *Boolean*,
- 3 pola typu *Enum*.

Natomiast w drugiej sekcji znajdowały się:

- 1 pole typu *String* będące kluczem obcym,
- 3 pola typu *Integer*,
- 1 pole typu *Enum*,
- 2 pola typu *BigDecimal*.

Opis poszczególnych pól w pliku w sekcji pierwszej:

1. oznaczenie sekcji - „M”
2. identyfikator zakładu – klucz główny
3. miasto, w jakim znajdował się zakład
4. ulica z numerem
5. kod pocztowy – 5 cyfr bez myślnika
6. nazwa zakładu
7. region
8. dwuliterowe oznaczenie paliwa stosowanego w zakładzie
9. data rozpoczęcia działania zakładu
10. data zakończenia działania zakładu
11. data ostatniej modernizacji zakładu
12. moc produkcyjna zakładu
13. typ osiąganej mocy
14. flaga oznaczająca możliwość zdalnego sterowania produkcją
15. oznaczenie poziomu napięcia przy produkcji
16. identyfikator jednostki pomiarowej
17. typ zakładu
18. liczba określająca poziom ochrony przed hałasem

19. flaga oznaczająca bonus dla biogazowni
20. flaga oznaczająca dodatkowy bonus dla bio-ciepłowni.

Opis poszczególnych pól w pliku w sekcji drugiej:

1. oznaczenie sekcji - „A”
2. identyfikator zakładu – klucz obcy
3. typ raportu
4. rok produkcji
5. miesiąc produkcji
6. dzień produkcji – może być pusty dla raportów miesięcznych
7. ilości wyprodukowanej energii
8. kwota do zapłaty

Przykład wygenerowanych danych:

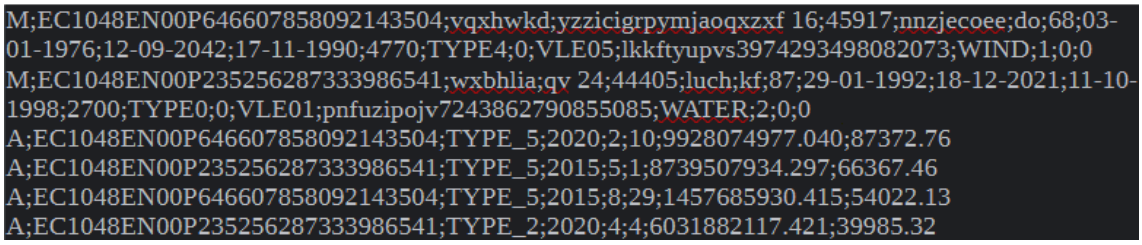

Rys. 1. Przedstawiający przykład wygenerowanych danych użytych w badaniu.

Pliki miały rozmiary od 100MB do 4GB. Większe pliki ze względu na zajętość pamięci nie były testowane.

Rozmiary testowanych plików:

- 100MB
- 250MB
- 500MB
- 1GB
- 2GB
- 4GB

2.2. Model danych

W tym podrozdziale został opisany moduł modelu danych znajdujących się w pliku *CSV.*

Moduł modelu zawiera następujące klasy:

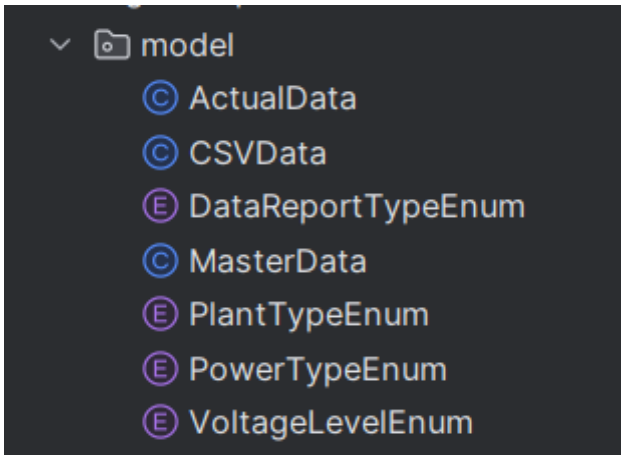

Rys. 2. Przedstawiający klasy w module modelu.

Klasa MasterData jest odwzorowaniem sekcji pierwszej z pliku *CSV*, a klasa *ActualData* jest odwzorowaniem sekcji drugiej.

Klasa *CSVData* jest nadklasą dla *MasterData* oraz *ActualData*. Zawiera ono jedno pole *masterKey*, które jest identyfikatorem zakładu.

Pola w klasie *MasterData*:

- *String masterKey*
- *String city*
- *String street*
- *String postCode*
- *String name*
- *String region*
- *Integer fuel*
- *Date startDate*
- *Date endDate*

- *Date modificationDate*
- *Integer power*
- *PowerTypeEnum powerType*
- *Boolean controllability*
- *VoltageLevelEnum voltageLevel*
- *String measurementLocationId*
- *PlantTypeEnum plantType*
- *Integer soundOptimization*
- *Boolean isBiomassBonus*
- *Boolean isBiomassTechnologyBonus*

Pola w klasie *ActualData*:

- *String masterKey*
- *DataReportTypeEnum dataReportType*
- *Integer year*
- *Integer month*
- *Integer day*
- *BigDecimal quantity*
- *BigDecimal amount*

Wartości enumeratorów:

- *DataReportTypeEnum*:
  TYPE_1, *TYPE_2*, *TYPE_3*, *TYPE_4*, *TYPE_5*, *TYPE_6*
- *PlantTypeEnum*:
  SOLAR, *BIOMASS*, *COAL*, *WIND*, *ATOM*, *WATER*, *GAS*, *GEOTHERMAL*
- *PowerTypeEnum*:
  TYPE0, *TYPE1*, *TYPE2*, *TYPE3*, *TYPE4*, *TYPE5*

- *VoltageLevelEnum*:
  VLE00, *VLE01*, *VLE02*, *VLE03*, *VLE04*, *VLE05.*

W każdej klasie wszystkie pola są prywatne, a dostęp do nich zapewniany jest za pomoc getterów oraz seterów. W klasie zostały nadpisane metody *equal()*, *hashcode()* oraz *to-String()*.

2.3. Generowanie danych

Dane do plików *CSV* zostały wygenerowane przez za pomocą napisanego programu. Program ten generował każdą linię osobno, dokonując konkatenacji za pomocą średników, a następnie otrzymaną linie zapisywał w pliku o rozszerzeniu .csv. Plik składał się z 2 części, przy czym pierwsza część stanowiła 10% wierszy.

Generowane pliki miały różne rozmiary w zależności od ilości wierszy. Przyjmuje się, że 12000 wierszy wygeneruje ok. 1MB plik. Każdy wygenerowany plik może mieć nieco różniący się od siebie rozmiar przy zachowaniu tej samej liczby wierszy.

Generator zawiera pakiet randomizer, który zawiera w sobie: 2 interfejsy z definicją metody generowania danych, klasę pomocniczą oraz 10 implementacji metod interfejsów w zależności od typu danych:

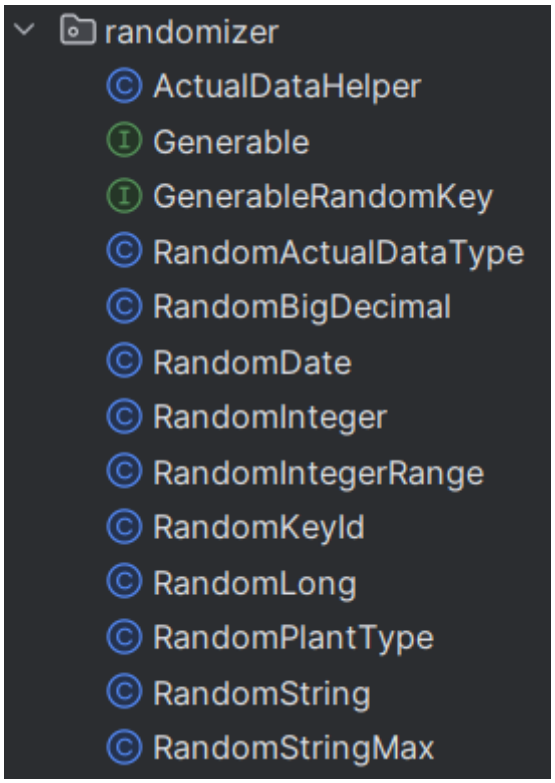

Rys. 3 przedstawiający strukturę pakietu randomizer dla generatora plików.

Interfejs *Generable<T>* zawiera jedną metodę o sygnaturze *T generate(String... args)*. Jej implementacja generuje wartości dla argumentów podanych jako String.

Drugi z interfejsów *GenerableRandomKey<T>* rozszerza poprzedni interfejs o dodatkową metodę *String getExistRandomKeyId()*. Służy ona do pobrania wygenerowanych już kluczy głównych, aby druga sekcja miała połączenie z pierwszą.

Klasa pomocnicza *ActualDataHelper* posiada jedną metodę *checkUniqueness*, która dla parametrów masterKey, dataReportType, rok, miesiąc i dzień sprawdzi, czy dana sekwencja klucza złożonego już została wygenerowana oraz zwróci odpowiednią wartość *true* lub *false*. Dodatkowe jeśli taki rekord nie zostanie znaleziony w zbiorze, to nowy rekord zostanie zapisany w pamięci.

Omówienie implementacji w klasach:

- *RandomInteger* – przyjmuje jeden argument i generuje losową liczbę całkowitą nie większą niż podany parametr.
- *RandomIntegerRange* – przyjmuje 2 argumenty i generuje losową liczbę całkowitą w przedziale między pierwszą a drugą wartością parametru.
- *RandomLong* - przyjmuje 2 argumenty i generuje losową liczbę zmiennoprzecinkową z przedziału między pierwszą a drugą wartością parametru.
- *RandomBigDecimal* – przyjmuje 2 argumenty, gdzie pierwszy z nich to precyzja wygenerowanej liczby stałoprzecinkowej, a drugi argument to maksymalna wartość *BigDecimal*.
- *RandomString* - przyjmuje 1 argument i generuje losowy ciąg znaków o podanej w parametrze długości.
- *RandomStringMax* - przyjmuje 1 argument i generuje losowy ciąg znaków o maksymalnej długości podanej w parametrze.
- *RandomDate* - przyjmuje 2 argumenty i generuje losową datę z przedziału podanych w parametrach dat.
- *RandomActualDataType* – nie przyjmuje argumentów, generuje ciąg znaków o prefiksie „TYPE_” oraz sufiksie będącym losową cyfrą z przedziału 1-6
- *RandomPlantType* – nie przyjmuje argumentów, losuje liczbę z przedziału 0-7 i dla wylosowanej liczby wybiera kolejno *SOLAR, BIOMASS, COAL, WIND, ATOM, WATER, GAS, GEOTHERMAL*.
- *RandomKeyId* – jako jedyny implementuje drugi interfejs *GenerableRandomKey*. W metodzie *generate()* nie przyjmuje żadnych argumentów i generuje ciąg znaków o stałym prefiksie „EC1048EN00P” oraz sufiksie będącym losową 18 cyfrową liczbą. Wygenerowany klucz zostaje następnie zapisany na liście wszystkich kluczy.

Druga metoda *getExistRandomKeyId()* pobiera z listy klucz o losowy indeksie.

Klasa *GenerateLine* służy do generowania w postaci *String'a* poszczególnych linii pierwszej bądź drugiej sekcji pliku *CSV*, zgodnie z modelem danych z poprzedniego rozdziału. W swoim działaniu wywołuje ona klasy z pakietu randomizer.

Klasa *GenerateCSVFile* służy do utworzenia nowego pliku o określonej nazwie oraz odpowiedniej ilości wierszy, a także wskazuje postęp w generowaniu danych w pliku. Wywołuje ona klasę *GenerateLine*.

2.4. Walidacja

Ten podrozdział opisuje założenia odnoszące się do walidacji plików oraz zależności między poszczególnymi polami.

Moduł walidacji zawierał w sobie klasy:

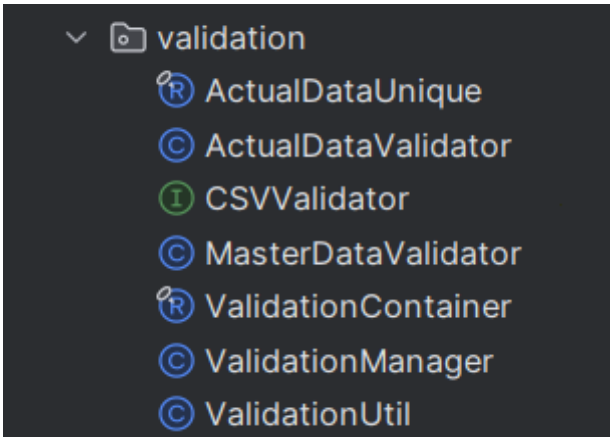

Rys. 4 przedstawiający klasy w module walidacji.

Klasą wywoływaną do przeprowadzenia walidacji była klasa *ValidationManager* i metoda *isValid(ValidationContainer, String)*. Przyjmuje ona za parametry instancję *ValidationContainer'a* oraz ciąg znaków pierwszego tokenu, aby rozpoznać sekcję i dobrać odpowiednią klasę do walidacji: *MasterDataValidator* lub *ActualDataValidator.*

ValidationContainer zawiera w sobie następujące pola:

- *String[]* - jako tablicę tokenów, czyli pojedynczych elementów rekordu z pliku CSV,
- *CSVData* – jako obiekt zmapowania tokenów na docelowy typ danych,
- *Set<String>* zbiór identyfikatorów zakładów, dodawany po każdej kolejnej walidacji sekcji pierwszej oraz sprawdzany w sekcji drugiej,
- *Set<ActualDataUnique>* zbiór kluczy złożonych, sprawdzany i dodawany po każdej kolejnej walidacji sekcji drugiej,
- *List<String>* - jako lista wszystkich zwróconych błędów walidacji,
- *int* – jako numer obecnie walidowanej linii z pliku – informacja dla użytkownika przy błędach walidacji.

Klasy *MasterDataValidator* i *ActualDataValidator* implementują interfejs *CSVValidator*, który zawiera sygnaturę metody *validate(ValidationContainer)*.

Implementacja tej metody w klasie *MasterDataValidator* sprawdza na początku poprawność ilości tokenów w tablicy. Powinno ich być 20. Jeśli w tym lub innym przypadku nastąpi niezgodność z walidacją, do kolekcji błędów zostanie dodany odpowiedni wpis. Następnie każdy kolejny token po kolei:

1. *Section* – sprawdzony wcześniej w *ValidatorManager.*
2. *MasterKey* – sprawdzane jest, czy token nie jest pusty oraz, czy jego długość jest równa 29 znaków oraz, czy w *ValidationContainer* nie istnieje już taki identyfikator zakładu. Na koniec do *ValidationContainer* dodawany jest walidowany identyfikator oraz w obiekcie *MasterData* ustawiana jest wartość pola *masterKey.*
3. *City* - sprawdzane jest, czy token nie jest pusty oraz, czy jego długość nie jest większa niż 256 znaków. Na koniec w obiekcie *MasterData* ustawiana jest wartość pola *city.*
4. *Street* - sprawdzane jest, czy token nie jest pusty oraz, czy jego długość nie jest większa niż 256 znaków. Na koniec w obiekcie *MasterData* ustawiana jest wartość pola *street*.
5. *PostCode* - sprawdzane jest, czy token nie jest pusty oraz, czy jego długość jest równa 5 znaków. Na koniec w obiekcie *MasterData* ustawiana jest wartość pola *postCode*.
6. *Name* - sprawdzane jest, czy token nie jest pusty oraz, czy jego długość nie jest większa niż 256 znaków. Na koniec w obiekcie *MasterData* ustawiana jest wartość pola *name*.
7. *Region* - sprawdzane jest, czy token nie jest pusty oraz, czy długość tokenu jest równa 2 znakom. Na koniec w obiekcie *MasterData* ustawiana jest wartość pola *region*.
8. *Fuel* - sprawdzane jest, czy token nie jest pusty oraz, czy jest liczbą mniejszą od 100. Na koniec w obiekcie *MasterData* ustawiana jest wartość pola *fuel*.
9. *StartDate* - sprawdzane jest, czy token nie jest pusty oraz, czy jest poprawną datą. Na koniec w obiekcie *MasterData* ustawiana jest wartość pola *startDate*.

10. *EndDate* - sprawdzane jest, czy token jest pusty lub jest poprawną datą. Data ta musi być po dacie *startDate*. Na koniec w obiekcie *MasterData* ustawiana jest wartość pola end*Date*.

11. *ModificationDate* - sprawdzane jest, czy token jest pusty lub jest poprawną datą. Data ta musi być pomiędzy datą *startDate*, a *endDate.* Na koniec w obiekcie *MasterData* ustawiana jest wartość pola *modificationDate*.

12. *Power* - sprawdzane jest, czy token nie jest pusty oraz, czy jest liczbą nie ujemną. Na koniec w obiekcie *MasterData* ustawiana jest wartość pola *power.*

13. *PowerType* - sprawdzane jest, czy token nie jest pusty oraz, czy jego długość jest równa 5 znaków. Następnie sprawdzane jest czy istnieje enum *powerTypeEnum* o wartości podanej w tokenie. Na koniec w obiekcie *MasterData* ustawiana jest wartość pola *powerType*.

14. *Controllability* - sprawdzane jest, czy token nie jest pusty oraz jeśli wartość jest równa 0, to wartość pola *Controllability* w obiekcie *MasterData* jest ustawiana na *False*, natomiast jeśli wartość tokenu jest równa 1, wtedy pole *Controllability* ustawiane jest na *True*.

15. *VlotageLevel* - sprawdzane jest, czy token nie jest pusty oraz, czy jego długość jest równa 5 znaków. Następnie sprawdzane jest, czy istnieje enum *VoltageLevelEnum* o wartości podanej w tokenie. Na koniec w obiekcie *MasterData* ustawiana jest wartość pola *VlotageLevel*.

16. *MeasurementLocationId* - sprawdzane jest, czy token nie jest pusty oraz, czy jego długość jest równa 26 znaków. Na koniec w obiekcie *MasterData* ustawiana jest wartość pola *MeasurementLocationId*.

17. *PlantType* - sprawdzane jest, czy token nie jest pusty. Następnie sprawdzane jest, czy istnieje enum *PlantTypeEnum* o wartości podanej w tokenie. Na koniec w obiekcie *MasterData* ustawiana jest wartość pola *plantType*.

18. *SoundOptimization* - sprawdzane jest, czy token nie jest pusty oraz, czy jest liczbą z przedziału od 0 do 2 włącznie. Na koniec w obiekcie *MasterData* ustawiana jest wartość pola *SoundOptimization*.

19. *IsBiomassBonus* - sprawdzane jest, czy token nie jest pusty oraz jeśli wartość jest równa 0, to wartość pola *IsBiomassBonus* w obiekcie *MasterData* jest ustawiana na

False, natomiast jeśli wartość tokenu jest równa 1, wtedy pole *IsBiomassBonus* ustawiane jest na *True*.

20. *IsBiomassTechnologyBonus* - sprawdzane jest, czy token nie jest pusty oraz jeśli wartość jest równa 0, to wartość pola *IsBiomassTechnologyBonus* w obiekcie *MasterData* jest ustawiana na *False*, natomiast jeśli wartość tokenu jest równa 1, wtedy pole *IsBiomassTechnologyBonus* ustawiane jest na *True*.

Podobnie jak implementacja w klasie *MasterDataValidator*, tak w klasie Actual*DataValidator* sprawdzana jest na początku poprawność ilości tokenów w tablicy. Powinno ich być 8. Jeśli w tym lub innym przypadku nastąpi niezgodność z walidacją, do kolekcji błędów zostanie dodany odpowiedni wpis.

Następnie każdy kolejny token po kolei:

1. *Section* - sprawdzony wcześniej w *ValidatorManager.*
2. *MasterKey* – sprawdzane jest, czy token nie jest pusty oraz, czy długość tokenu jest równa 29 znaków oraz czy w *ValidationContainer* istnieje taki identyfikator zakładu. Na koniec w obiekcie *ActualData* ustawiana jest wartość pola *masterKey.*
3. *DataReportType* - sprawdzane jest, czy token nie jest pusty. Następnie sprawdzane jest, czy istnieje enum *DataReportTypeEnum* o wartości podanej w tokenie. Na koniec w obiekcie *ActualData* ustawiana jest wartość pola *dataReportType*.
4. *Year* - sprawdzane jest, czy token nie jest pusty oraz, czy jest liczbą z przedziału od 1900 do 2100 łącznie. Na koniec w obiekcie Actual*Data* ustawiana jest wartość pola *year.*
5. *Month* - sprawdzane jest, czy token jest lub oraz, czy jest liczbą z przedziału od 0 do 12 włącznie. Na koniec w obiekcie Actual*Data* ustawiana jest wartość pola *month*.
6. *Day* - sprawdzane jest, czy token nie jest pusty oraz, czy jest liczbą z przedziału od 0 do 31 łącznie. Na koniec w obiekcie Actual*Data* ustawiana jest wartość pola *day.*
7. *Quantity* - sprawdzane jest, czy token nie jest pusty oraz, czy jest liczbą dodatnią z dokładnością mniejszą niż 4 miejsca po przecinku. Na koniec w obiekcie Actual*Data* ustawiana jest wartość pola *quantity.*

8. *Amount* - sprawdzane jest, czy token nie jest pusty oraz, czy jest liczbą dodatnią z dokładnością mniejszą niż 3 miejsca po przecinku. Na koniec w obiekcie *ActualData* ustawiana jest wartość pola *amount*.

Dodatkowo po walidacji tokenów, sprawdzane jest, czy podana w 3 kolumnach data jest poprawna. W przypadku braku dnia sprawdzana jest data z pierwszym dniem miesiąca. Ostatnią walidacją jest sprawdzenie, czy zachowany jest klucz złożony z pól *masterKey*, *dataReportType*, *year*, *month*, *day*. Aby tego dokonać, tworzone są obiekty pomocnicze *ActualDataUnique*, o wymienionych wcześniej polach. Następnie sprawdzane jest, czy taki obiekt nie istnieje już w kolekcji *actualDataUniques* w *ValidationContainer.*

2.5. Wczytywanie danych

W tym podrozdziale zostały opisane metody używane do odczytu danych z plików *CSV* oraz ich użycie.

Moduł wczytywania:

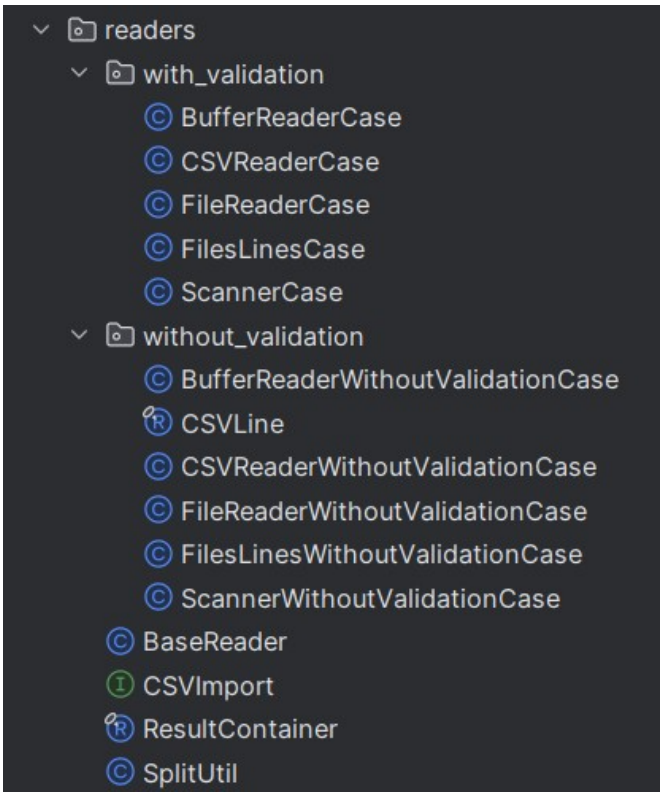

Rys. 5 pokazujący klasy w module wczytywania.

Klasa *ResultContainer* zawiera w sobie 3 listy danych takich jak:

- masterDataList – kolekcja zawierająca wszystkie obiekty *MasterData* z pliku *CSV*,
- actualDataList – kolekcja zawierająca wszystkie obiekty *ActualData* z pliku *CSV*,
- errors – kolekcja zawierająca wszystkie błędy zebrane podczas walidacji pliku *CSV*.

Klasa *SplitUtil* jest klasą narzędziową, czyli taką, która posiada tylko metody statyczne oraz nie przechowuje żadnego stanu.[3] Zawiera ona jedną metodę *splitLine()*, która z parametru *String*, będącego linią z pliku zwraca tablicę tokenów. Działa ona na zasadzie przeszukiwania kolejnych wystąpień znaku separatora *CSV* i tworzenia podciągów od ostatniego do obecnego wystąpienia znaku „*;*”. Kolejne tworzone w ten sposób podciągi są doda-

[3]C. Sanecki, *Klasy Utility - zwykłe lenistwo czy zło konieczne?*, 2021, https://cezarysanecki.pl/2021/02/17/klasy-utility-zwykle-lenistwo-czy-zlo-konieczne/ (dostęp 14.09.2025).

wane do listy wiązanej, a na końcu za pomocą metody *toArray()* zwracane do postaci tablicy tokenów o typie *String*.

Klasa *BaseReader* zawiera metodę validate(), która odpowiada za wywołanie walidacji danej tablicy tokenów oraz tworzenie obiektów pomocniczych takich jak *ValidationContainer*. Każdy z przypadków testowych korzysta z tej metody walidacji, dzięki czemu można założyć, że walidacja obiektów dla każdego z przypadków jest taka sama.

W tej części zostało opisane 5 klas do wczytywania plików.

2.5.1. FileReader

Opis teoretyczny

FileReader jest to klasa z pakietu *java.io* i rozszerza klasę *InputStreamReader*. Klasa ta służy do wczytywania danych z plików jako strumienie znaków.[4]

W klasie tej znajdują się 3 konstruktory, każdy z nich jednoargumentowy. Przyjmują one parametry: *File*, *FileDescriptor* lub *String*. Konstruktor może zgłosić wyjątek *FileNotFoundException* w momencie, gdy plik, lub nazwa nie istnieją, bądź są folderami.

Metoda *read()* odczytuje i zwraca z pliku kolejne znaki. Gdy skończą się dane w pliku, metoda zwraca wartość -1.[5] Co istotne, zależności od kodowania znak może zawierać różną ilość bajtów. Metoda ta jest mało efektywna, ponieważ za każdym razem wczytuje tylko jeden znak i często odwołuje się do pamięci dyskowej.

Sposobem na ten problem może być użycie metoda *read(char[] cbuf)*, której implementacja znajduje się w klasie *Reader*. Metoda ta wczytuje znaki do podanej tablicy. Będzie tak, dopóki: dane wejściowe są dostępne lub zakończono czytanie znaków lub wystąpi błąd wejścia/wyjścia. Metoda zwraca liczbę znaków, jakie zostały wczytane do bufora. Może się zdarzyć, że metoda zgłosi wyjątek *IOExcepotion*.[6]

Odczytywania znaków za pomocą bufora może z łatwością zwiększyć wydajność kilkunastokrotnie. Jednak ma on swoje limity. Jak podaje J. Jenkov „Jeśli rozmiar tablicy będzie większy niż możliwości systemu operacyjnego bądź sprzętu, nie będzie to skutkowało

[4] J. Jenkov, *Java FileReader*, 2021, https://jenkov.com/tutorials/java-io/filereader.html (dostęp. 09.09.2025).
[5] *Java FileReader Class*, 2025, https://www.geeksforgeeks.org/java/java-io-filereader-class/ (dostęp. 09.09.2025).
[6] Oracle, *Class InputStreamReader*, https://docs.oracle.com/javase/8/docs/api/java/io/Reader.html#read-- (dostęp. 09.09.2025).

wzrostem prędkości z tytułu większej tablicy znaków."[7]

Klasa ta implementuje interfejsy *Closeable* oraz *AutoCloseable*. Oznacza to, że po zakończeniu działań na pliku należy wywołać metoda *close()*, aby zwolnić pamięć oraz zasoby systemowe. Aby ułatwić proces, można użyć mechanizmu *try-with-resources*, który automatycznie wywoła metodę *close()*.[8]

Według specjalistów z Oracle aż 60% kodu, który korzystał z zasobów w *JDK* 6, było nieprawidłowo obsłużone. Wniosek jest prosty, jeśli nawet inżynierowie tworzący język miewają problemy z obsługą zasobów, należy oddelegować tę akcję używając t*ry-with-resources*.[9]

Opis algorytmu z walidacją podczas wczytywania

Algorytm ten używa metody *fileReader.read(buffer)* do pobrania kolejnych znaków do 256 znakowego buforu. Następnie przechodząc po każdym znaku sprawdza, czy jest on komentarzem „*#"*, znakiem separatora „*;"*, czy znakiem końca linii „\n" lub „\r". W przypadku komentarza przechodzi przez bufor do czasu znalezienia znaku końca linii. W przypadku znaku separatora dodaje nowy token do listy tokenów przez utworzenie nowego obiektu String z bufora od wartości ostatniego indeksu przez długość czytania bufora, zanim znaleziono separator. Następnie jako nowy ostatni indeks ustawiany jest kolejny znak z buforu.

W przypadku znaku końca linii do listy tokenów dodawany jest ostatni ciąg znaków tak jak wyżej. Następnie z listy tokenów tworzona jest tablica tokenów poprzez użycie metody *toArray()*. W kolejnym kroku następuje wywołanie metody *validate()* z parametrami: lista tokenów, lista identyfikatorów zakładów, lista kluczy złożonych z sekcji drugiej, numer linii oraz kontener rezultatu. Po walidacji lista tokenów jest czyszczona.

Gdy pętla przejdzie przez cały bufor, sprawdzone jest, czy ostatni indeks separatora jest ostatnim znakiem pobranym z bufora. Jeśli nie to pozostałość zostanie dodane do następnego tokenu. Na koniec pętli wczytywana jest kolejny ciąg znaków do buforu.

Opis algorytmu z walidacją po wczytaniu wszystkich danych:

W porównaniu do wersji poprzedniej tutaj, zamiast tworzyć listę tokenów, tworzona jest

[7] J. Jenkov, *Java FileReader,* dz. cyt, 22.
[8] Oracle, *Interface AutoCloseable*, https://docs.oracle.com/javase/8/docs/api/java/lang/AutoCloseable.html (dostęp. 09.09.2025).
[9] B. J. Evans, J. Clark, D. Flanagan, *Java in a Nutshell*, O'Reilly Media, Sebastopol 2019, s. 452.

pełna linia z pliku *CSV*, a zamiast metodę walidacji, dodawany jest nowy obiekt *CSVLine* do listy wszystkich linii. *CSVLine* zawiera 2 pola i są to: *String* z linią z pliku oraz *int* numer wiersza potrzebny do wskazywania błędów podczas walidacji.

Po wczytaniu wszystkich linii do listy *csvLines* następuje iterowanie po każdym elemencie tej kolekcji oraz parsowanie linii z *CSVLine* do tablicy *String* z wykorzystaniem *SplitUtil.splitLine()*. Następnie wykonywana jest metoda *validate()* z odpowiednimi parametrami. Po walidacji element na liście *csvLines* jest ustawiany na *null*, aby umożliwić szybsze zwolnienie pamięci.

2.5.2. BufferedReader

Opis teoretyczny

Klasa *BufferedReader* jest klasą z pakietu *java.io* i rozszerza klasę *Reader*. Zgodnie z dokumentacją klasa ta „odczytuje tekst ze strumienia znaków wejściowych, buforując znaki w celu zapewnienia wydajnego odczytywania znaków, tablic i wierszy.”[10]

Klasa zawiera 2 konstruktory. Pierwszy przyjmuje parametr *Reader* oraz *int*, tworząc tym samym buforowany strumień znaków, dla bufora wejściowego oraz rozmiaru tego bufora. Drugi z konstruktorów przyjmuje tylko jeden argument *Reader*, a wielkość bufora jest ustawiana na domyślne 8kb.[11]

Metodą najczęściej używaną w tej klasie jest *readLines()*, która to wczytuje oraz zwraca String z kolejną linią ze strumienia. Jak podaje dokumentacja *Oracle* „Uznaje się, że wiersz jest zakończony przez jedną z sytuacji: wystąpienie znaku końca wiersza ('\n'), powrót karetki ('\r'), powrót karetki, po którym następuje koniec wiersza lub dotarcie do końca pliku (*EOF*).”[12]. Znak rozdzielający kolejne linie nie jest zwracany. Gdy metoda dojdzie do końca pliku zwróci, wartość *null*, stąd bardzo częste wykorzystywanie jej w pętli *while*.[13] Metoda może zgłosić wyjątek *IOException*.

BufferedReader poprawia efektywność odczytu strumienia znaków np. *FileReader'a*. Dla-

[10]Oracle, *Class BufferedReader*, https://docs.oracle.com/javase/8/docs/api/?java/io/BufferedReader.html (dostęp. 09.09.2025).
[11]Tamże, 24.
[12]Oracle *Class BufferedReader*, https://docs.oracle.com/en/java/javase/24/docs/api/java.base/java/io/BufferedReader.html#readLine() (dostęp. 09.09.2025).
[13]K. Sierra, B. Bates, *Java. Rusz głową!*, tł. P. Rajca, Helion, Gliwice 2011. s. 477-481.

tego ich wspólne stosowanie jest bardzo częste. Podczas gdy *FileReader* łączy się z plikiem, to *BufferedReader* zapewnia, że odczyty z dysku nie będą zbyt częste.[14]

Podobnie jak w przypadku *FileReader* klasa ta implementuje interfejsy *Closeable* oraz *AutoCloseable*. Oznacza to, że po zakończeniu działań na pliku należy wywołać metoda *close()*. Zalecane jest użycie mechanizmu *try-with-resources*, który wystarczy użyć na klasie *BufferedReader*, a *Reader* zostanie zamknięty automatycznie.[15]

Opis algorytmu z walidacją podczas wczytywania:

Algorytm ten używa metody *bufferedReader.readLine()* do pobrania kolejnych linii z pliku *CSV.* Następnie, dopóki linia nie jest pusta sprawdza, czy pierwszy znak jest komentarzem „*#”*. W takim przypadku pobiera kolejną linię z pliku.

W kolejnym kroku parsuję linię do tablicy *String* z wykorzystaniem *SplitUtil.splitLine()*. Później następuje wywołanie metody *validate()* z odpowiednimi parametrami. Na koniec pętli wczytywany jest kolejny wiersz z pliku.

Opis algorytmu z walidacją po wczytaniu wszystkich danych:

W porównaniu do wersji powyżej nie następuje parsowanie oraz walidacja, tylko do listy wierszy csv*Lines* dodawane są kolejne linii z pliku *CSV.*
Po wczytaniu całości następuje przejście po całej kolekcji *csvLines* i każda linia jest parsowana do postaci tablicy *String[]* oraz wywoływana jest metoda *validate()* z odpowiednimi parametrami. Po walidacji element na liście *csvLines* jest ustawiany na *null*, aby umożliwić szybsze zwolnienie pamięci.

2.5.3. Scanner

Opis teoretyczny

Klasa *Scanner* jest klasą z pakietu *java.util*. Służy do odczytywania kolejnych tokenów ze źródła. Jak podaje *Oracle* w swojej dokumentacji „*Scanner* dzieli dane wejściowe na tokeny przy użyciu wzorca ogranicznika, który domyślnie pasuje do białych znaków. Powstałe

[14]Tamże, 24.
[15]J. Jenkov, *Java BufferedReader*, https://jenkov.com/tutorials/java-io/bufferedreader.html (dostęp. 09.09.2025).

tokeny można następnie przekształcić w wartości różnych typów przy użyciu różnych kolejnych metod."[16]

Konstruktorów w klasie jest aż 14. Dzielą się na grupy, które mogą przyjmować: *InputStream* – najczęściej używany przypadek, często wykorzystywany z *System.in* do odbierania danych do użytkownika, *String* lub *ReadableByteChannel*, do pracy na łańcuchach znaków lub bajtów, *File* bądź *Path*, do działa z plikami. Konstruktory jako drugi parametr mogą przyjmować kodowanie znaków w przypadku, gdy nie ma zostać użyte inne niż domyślne *UTF-8*.[17]

Najczęściej używanymi metodami są *hasNext()* oraz *next()* i ich odpowiedniki dla różnych typów np. *hasNextInt()* oraz *nextInt()*, *hasNextLong()* oraz *nextLong()*.

Metoda *hasNext()* zwraca wartość true, gdy istnieje kolejny token na wejściu. Metoda ta blokuje proces, czekając na dane. Sprawdzenie, czy istnieje token nie wpływa na iterator scannera. Natomiast metoda *next()* zwraca wartość kolejnego tokena. Domyślnie obie metody jako ogranicznika używają białych znaków.[18]

W przypadku użycia *Scannera* do działania z konsolą użytkownika nie ma stosuje się sprawdzenia *hasNext()*, lecz gdy działamy na innych typach źródeł np. plikach, taka informacja jest bardzo pomocna.[19]

Wariancją powyższych metod jest *hasNextLine()* oraz *nextLine()*. Co do zasady działają podobnie, jednak jako ogranicznik używają znaków końca linii. Dodatkowo metoda sprawdzająca *hasNextLine()* może przechować w pamięci linie do zwrócenia, dzięki temu metoda *nextLine()* szybciej zwróci rezultat.

Podobnie jak w przypadku klas *Reader*, *Scanner* również implementuje interfejsy *Closeable* oraz *AutoCloseable* i również po zakończeniu działań na pliku bądź innym źródle należy zamknąć *Scanner.* Najlepiej do tego celu sprawdzi się mechanizm try-with-resources. Należy jednak pamiętać, że zamknięcie *Scannera*, który korzysta z *System.in,* sprawi, że nie będzie mógł być użyty więcej razy.[20]

---

[16]Oracle, *Class Scanner*, https://docs.oracle.com/javase/8/docs/api/java/util/Scanner.html (dostęp: 09.09.2025).
[17]P. Kumar, *Scanner Class in Java*, https://www.digitalocean.com/community/tutorials/scanner-class-in-java (dostęp: 09.09.2025).
[18]W3Schools, *Java Scanner Methods*, https://www.w3schools.com/java/java_ref_scanner.asp (dostęp: 09.09.2025).
[19]R. Morelli i R. Walde, *Java, Java, Java Object-Oriented Problem Solving,* Trinity College, Hartford 2017 s. 183-187.
[20]W3Schools *Java Scanner... dz. cyt, 26.*

Opis algorytmu z walidacją podczas wczytywania:

Algorytm ten sprawdza używając *scanner.hasNextLine()* czy w pliku *CSV* znajdują się kolejne linie i pobiera każdą z nich poprzez *scanner.nextLine()*. Następnie dla każdej linii sprawdzane jest, czy nie jest pusta oraz, czy pierwszy znak jest komentarzem #. W takim przypadku pobiera kolejną linię z pliku.

W kolejnym kroku parsuję linię do tablicy *String[]* z wykorzystaniem *SplitUtil.splitLine()*. Później następuje wywołanie metody *validate()* z odpowiednimi parametrami.

Opis algorytmu z walidacją po wczytaniu wszystkich danych:

Algorytm podobnie jak w poprzednich rozwiązaniach z walidacją po wczytaniu pliku, nie następuje parsowanie oraz walidacja, tylko do listy wierszy csv*Lines* dodawane są kolejne linii z pliku *CSV.*

Po wczytaniu całości następuje przejście po całej kolekcji *csvLines* i każda linia jest parsowana do postaci tablicy *String[]* oraz wywoływana jest metoda *validate()* z odpowiednimi parametrami. Po walidacji element na liście *csvLines* jest ustawiany na *null*, aby umożliwić szybsze zwolnienie pamięci.

2.5.4. Files.lines()

Opis teoretyczny

Klasa *Files* to klasa narzędziowa z pakietu *java.nio.file*. Dostarcza ona wiele pomocnych metod do pracy z plikami.

Metoda *lines(Path path)*, służy do wczytania wierszy z pliku i zwrócenia ich w postaci strumienia zgodnie ze standardem *Stream API*. Istnieje przeciążenie tej metody z dodatkowym argumentem *Charset*, który nadpisuje domyślne kodowanie znaków *UTF-8*. Metoda lines wykorzystuje *lazy loading*, czyli wczytuje kolejne linie w momencie kiedy są używane. Metoda ta może zgłosić *IOException* lub często owinięty błąd *UncheckedIOException*.

Jak wskazuje dokumentacja *Oracle* „Ta metoda musi być używana w instrukcji *try-with-resources* lub podobnej strukturze kontrolnej, aby zapewnić, że otwarty plik strumienia zostanie zamknięty natychmiast po zakończeniu operacji strumienia.”[21]

[21]Oracle, *Class Files*, https://docs.oracle.com/en/java/javase/24/docs/api/java.base/java/nio/file/Files.html (dostęp: 09.09.2025).

Stream API zostało wprowadzone, aby uprościć wykonywanie operacji zbiorczych w sposób sekwencyjny lub równoległy. Podstawą tego mechanizmu są dwa elementy: strumień, czyli ciąg danych pochodzących m. in. z kolekcji, tablic czy plików, oraz potok strumieniowy, opisujący kolejne etapy przetwarzania tych danych. Potok składa się ze źródła, operacji pośrednich (np. filtrowania, mapowania) oraz operacji końcowej. Kluczowym działaniem jest leniwe wykonywanie – operacje są realizowane dopiero przy wywołaniu operacji końcowej, co umożliwia pracę nawet na strumieniach nieskończonych. API jest również zaprojektowane w stylu płynnym, co pozwala łączyć wiele wywołań w jedną spójną konstrukcję.[22]

Opis algorytmu z walidacją podczas wczytywania:

W przypadku tego algorytmu wczytywanie następuje z wykorzystaniem strumieni używając *Files.lines()*.

Algorytm ten dla każdej linii z pliku *CSV* sprawdzane jest, czy nie jest ona pusta oraz czy pierwszy znak nie jest komentarzem #. W takim przypadku parsuję linię do tablicy *String[]* z wykorzystaniem *SplitUtil.splitLine()*. Później następuje wywołanie metody *validate()* z odpowiednimi parametrami.

Opis algorytmu z walidacją po wczytaniu wszystkich danych:

Podobnie jak w wersjach opartych na *BufferedReader* i *Scanner*, w tej implementacji nie wykonuje się parsowania ani walidacji danych podczas odczytu pliku. Zamiast tego, kolejne linie z pliku *CSV* są dodawane do listy *csvLines*. Dopiero po wczytaniu całego pliku następuje iteracja po elementach tej listy – każda linia jest przekształcana na tablicę typu *String[]*, a następnie przekazywana do metody *validate()* wraz z odpowiednimi argumentami. Po zakończeniu walidacji dana pozycja na liście csvLines zostaje ustawiona na null, co umożliwia wcześniejsze zwolnienie zajmowanej przez nią pamięci.

2.5.5. CSVReader

Opis teoretyczny

Klasa *CSVReader* pochodzi z biblioteki *com.opencsv*. Zawiera ona gotowe do użycia klasy pracujące na plikach *CSV*. Dzięki niej znacznie czytanie oraz zapis do plików *CSV* staje się

[22]J. Bloch, *Effective Java*, Addison Wesley, 2018, s. 203-209.

znacznie łatwiejsze. Ponadto jako jedno z niewielu zewnętrznych rozwiązań jest oparte na licencji *Apache 2.0.*[23]

W bibliotece *OpenCSV* dostępnych jest kilka praktycznych klas:

- *CSVReader* umożliwia odczyt pliku *CSV* do postaci łańcuchów znaków.
- *CSVWriter* służy do zapisywania danych w formacie *CSV.*
- *CsvToBean* pozwala mapować zawartość pliku *CSV* na obiekty typu *Java Bean*,
- *BeanToCsv* wspiera proces odwrotny do poprzedniego, czyli eksportowania danych z aplikacji Java do plików *CSV*.[24]

Klasa *CSVReader* posiada konstruktor z parametrem *Reader*, natomiast zalecanym sposobem tworzenia czytnika jest użycie klasy budowniczego *CSVReaderBuilder.* Dzięki niemu można w łatwy sposób skonfigurować wszystkie potrzebne parametry np. znak separatora lub pominąć pewną ilość linii.

Metoda *readNext()* służy do pobrania kolejnej linii z pliku oraz zwrócenia jej w postaci tablicy stringów. Jeśli danych w pliku już nie będzie, metoda ta zwróci null. Może zgłosić *IOException* oraz *csvValidationException*, gdy użytkownik zdefiniował reguły.[25]

Podobnie jak w przypadku pozostałych klasa *CSVReader* również implementuje interfejsy *Closeable* oraz *AutoCloseable*. Należy pamiętać o użyciu *try-with-resources* lub o zamknięciu zasobu po zakończonej pracy.

Opis algorytmu z walidacją podczas wczytywania:

Algorytm opiera swoje działanie na tokenach typu *String[]* pobieranych za pomocą *csvReader.readNext()* z pliku *CSV.* Następnie sprawdza, czy tablica tokenów jest różna od wartości *null*, kiedy to plik dobiegnie końca.

Następnie dla każdej tablicy tokenów sprawdzane jest, czy nie jest pusta oraz, czy pierwszy token nie zaczyna się od znaku komentarza „*#”*. W takim przypadku pobiera kolejną linię z pliku. W kolejnym kroku następuje wywołanie metody *validate()* z odpowiednimi parametrami, a na koniec pętli pobierany jest kolejna tablica tokenów z pliku *CSV.*

Opis algorytmu z walidacją po wczytaniu wszystkich danych:

[23]Opencsv, *Opencsv Users Guide*, 2025, https://opencsv.sourceforge.net/ (dostęp: 10.09.2025).
[24]*Reading a CSV file in Java using OpenCSV,* 2025, https://www.geeksforgeeks.org/java/reading-csv-file-java-using-opencsv/ (dostęp: 10.09.2025).
[25]Opencsv, *Class CSVReader*, https://opencsv.sourceforge.net/apidocs/com/opencsv/CSVReader.html#hasNext (dostęp: 10.09.2025).

Podobnie jak we wersjach wcześniejszych, w implementacji tej nie wykonuje się parsowania ani walidacji danych podczas odczytu pliku. Kroki te są rozdzielone na wczytanie kolejnych linii z pliku *CSV*, które dodawane są do listy *csvLines*.

Następnym krokiem jest iteracja po elementach wczytanych wierszy, gzie każda linia jest przekształcana do postaci *String[]* za pomocą metody *SplitUtil.splitLine()*, a następnie wywoływana jest metody *validate()* wraz z odpowiednimi parametrami. Po walidacji wartość elementu na liście *csvLines* jest ustawiana na *null*, aby umożliwić szybsze zwolnienie części pamięci.

Podsumowanie rozdziału:

Łącznie było 6 plików o rozmiarach od 100MB do 4GB. Każdy plik był podzielony na 2 sekcje:

- pierwsza: 10% obiętości oraz 20 kolumn danych,
- druga: 90% obiętości oraz 8 kolumn danych.

Dane w plikach zostały wygenerowane przy pomocy osobnego generatora. Podczas działania programu następowała walidacja poszczególnych pól, jak i kluczy obcych tudzież złożonych.

Program implementował 5 algortymów do wczytywania danych: *BufferedReader*, *CSVReader*, *FileReader*, *Files.lines*, *Scanner*. Wszyskie te algorytmy zostały sprawdzone przy walidacji podczas wczytywania kolejnych wierszy oraz w przypadku, gdy najpierw cały plik *CSV* został wczytany do pamięci programu.

Na platformie testowej został uruchomiony program, który automatycznie zebrał wyniki czasu przetwarzania plików, jaki i zużytą do tego procesu pamięć. Drugim źródłem danych było narzędzie *Profiler*, z którego to ręcznie zostały pobrane dane o czasie przetwarzania poszczególnych etapów oraz całkowitej zaalokowanej pamięci.

3. Badania

Badania zostały przeprowadzone na 2 zestawach danych:

- dane zebrane z programu – 10 obserwacji,
- dane zebrane z narzędzie Profiler – 3 obserwacje.

W obu zbiorach dane zidentyfikowano oraz zredukowano wpływ wartości odstających obserwacji poprzez ponowienie danej obserwacji.

3.1. Testy statystyczne

Aby sprawdzić, czy dana różnica pomiędzy pomiarami jest na tyle duża, aby móc mówić o rzeczywistych efektach, a nie przypadku, posłużono się testami statystycznymi. Sprawdzano występowanie różnic pomiędzy grupami obserwacji za pomocą testu *Anova*. Aby możliwe było użycie tego testu, dane muszą mieć rozkład normalny oraz należy sprawdzić homogeniczność wariancji. Do tego celu użyto odpowiednio testów *Shapiro-Wilk* oraz *Levenes.* Aby dokładnie określić, które grupy są od siebie różne, użyto testu *post-hoc Tukey HSD.*

Poniżej opisano testy statystyczne użyte w badaniach.

3.1.1. Shapiro-Wilka

Jest to jeden z podstawowych testów w statystyce. Test ten sprawdza, czy badane wartości posiadają rozkład normalny. Jeśli dane mają rozkład normalny możliwe jest użycie testu *Anova*. W przeciwnym przypadku należy użyć innych – nieparametrycznych testów – takich jak: *Kruskala–Wallisa*, test *U Manna–Whitneya* lub test *Friedmana*.

Schemat działania:

Pierwszym krokiem jest ustalenie badanej hipotezy. Jak podaje strona pogotowiestatystyczne.pl „Hipoteza zerowa dla tego testu zakłada, że nasza próba badawcza pochodzi z populacji o normalnym rozkładzie.”[26].

Następnie oblicza się za pomocą odpowiedniego wzoru wartość *W*. Wartość ta wskazuje

[26]P. Iwankowski, *Test Shapiro-Wilka.* https://pogotowiestatystyczne.pl/slowniki/test-shapiro-wilka/ (dostęp: 06.09.2025).

jak bardzo wartości w próbie odbiegają od wartości z rozkładu normalnego. Im wartość *W* jest bliższa wartości 1, tym bliżej próbce do przyjęcia hipotezy H_0.

W kolejnym kroku wyznaczana jest wartość *p* na podstawie wartość *W* oraz ilości prób. Na podstawie wartości *p* można przyjąć, bądź odrzucić hipotezę H_0. „Jeśli test *Shapiro-Wilka* osiąga istotność statystyczną ($p < 0,05$), świadczy to o rozkładzie odbiegającym od krzywej *Gaussa*.”.[27] W przeciwnym przypadku uznaję się, że rozkład jest normalny.

Wszystkie dane otrzymane w badaniach zarówno z grup zebranych z programu, jak i grup zebranych z narzędzia Profiler mają rozkład normalny.

3.1.2. Levene

Test ten ocenia homogeniczność wariancji w próbach.

Jak podaje strona pogotowiestatystyczne.pl „Test *Levene’a* jest wykonywany standardowo przed wykonaniem obliczeń przy użyciu parametrycznych testów średnich – *t Studena* dla prób niezależnych oraz jednoczynnikowej analizie wariancji, ponieważ jednorodność wariancji jest ich istotnym założeniem. Jeśli wynik test Levene’a jest istotny statystycznie wykorzystujemy jedną z dostępnych “poprawek” na wynik.”[28]

Schemat działania:

Ustalenie hipotezy H_0 wskazującą na jednorodność wariancji. Następnie wyliczana jest odległość każdej obserwacji od średniej próby.

W kolejnym kroku obliczana jest wartość statystyki *F*. Następnie na podstawie wartości *F* oraz liczności próby wyliczana jest wartość *p*. Jeśli jest ona większa niż 0,05, oznacza to, że zachodzi homogeniczność wariancji.

W przypadku badanych danych znaczna większość grup miała statystycznie równe wartości wariancji, natomiast zdarzyły się 2 przypadki (badania pamięci z walidacją po wczytaniu całego pliku o rozmiarach 250MB oraz 4GB), dla których to test *Levene* wykazał różnice w wariancjach. Dla tych dwóch przypadków konieczne było użycie testu *Kruskal-Wallis’a*.

[27]Tamże, 31.
[28]P. Iwankowski, *Test Levene’a,* https://pogotowiestatystyczne.pl/slowniki/test-levenea/ (dostęp: 06.09.2025).

3.1.3. Jednoczynnikowa Anova

Test *Anova* służy do stwierdzenia czy pomiędzy kilkoma grupami danych zachodzą różnice w wartościach wariancji. Według pogotowiestatystyczne.pl „Polega ona na porównaniu wariancji międzygrupowej do wariancji wewnątrzgrupowej.”[29]. Istotną cechą tego testu jest to, że „Jeśli statystyka *F* jest mniejsza od 1, oznacza to, że wariancja niewyjaśniona (wewnątrzgrupowa) jest większa od wariancji wyjaśnionej (międzygrupowej).”[30]. Mówimy wtedy o trudnej do oceny sytuacji.

Aby użyć tego testu, należy spełnić 4 warunki:

1. Normalność rozkładu,
2. Jednorodność wariancji,
3. Niezależność obserwacji,
4. Zmienne w skali ilościowej.

Schemat działania:

Ustalenie hipotezy H_0 wskazującą na równość wszystkich sprawdzanych wariancji. Następnie oblicza się wariancją wewnątrzgrupową oraz międzygrupową. W kolejnym kroku obliczana jest wartość statystyki *F*. Następnie na podstawie wartości *F* oraz liczności próby wyliczana jest wartość *p*. Jeśli jest ona większa niż 0,05, oznacza to, przynajmniej jedna z grup różni się istotnie od pozostałych.

Aby dowiedzieć się, które grupy są różne stasuje się testy *post-hoc*. W tym przypadku posłużono się testem *Tukey HSD*.

Rezultaty tych testów oraz testów post-hoc pokazane są opisane w rozdziale 3.3.

3.1.4. Tukey HSD

Jest to jeden z testów *post-hoc*, służący do wskazywania grup obserwacji różniących się od siebie. Jak podaje sztos-it.com „Test *post-hoc Tukeya*, znany również jako *Tukey's Honest Significant Difference (HSD)*, to metoda stosowana w analizie wariancji (*ANOVA*) w celu porównania średnich różnych grup po uzyskaniu istotnego wyniku testu *ANOVA*. Pomaga on ustalić, które dokładnie grupy różnią się między sobą, podczas gdy *ANOVA* sama mówi nam jedynie, czy istnieją jakieś różnice między grupami, ale nie wskazuje, które grupy są

[29]P. Iwankowski, *Test ANOVA,* https://pogotowiestatystyczne.pl/slowniki/anova/ (dostęp: 06.09.2025).
[30]Tamże, 33.

różne.”[31]

Schemat działania:

Ustalenie hipotezy H_0 wskazującą na równość średnich wartości sprawdzanych grup. Następnie za pomocą odpowiedniego wzoru oblicza się wartość statystyki *q*. W kolejnym kroku obliczoną wartość statystyki *q* porównuje się do wartości granicznej dla danej liczby grup oraz stopni swobody. Jeśli wartość *q* jest większa, oznacza to, że sprawdzane grupy różnią się istotnie od siebie.

3.1.5. Kruskala-Wallisa

Jest to nieparametryczny test, służący do sprawdzania różnic pomiędzy grupami danych, odpowiednik *Anova*.

Jak podaje pogotowiestatystyczne.pl „test *Kruskala-Wallisa* jest testem nieparametrycznym, co oznacza, że możemy go wykorzystać wtedy, gdy niespełnione są założenia dotyczące stosowania testów parametrycznych lub gdy nasza zmienna zależna ma charakter porządkowy”.[32] Dzięki temu można użyć tego testu w przypadkach gdy jednorodność wariancji nie jest spełniona.

Schemat działania:

Ustalenie hipotezy H_0 wskazującą na równość wszystkich sprawdzanych median. Na początek wszystkie obserwacje zostają uszeregowane oraz przypisuje się im rangi. W kolejnym kroku obliczana jest wartość statystyki *H* oraz porównywana jest do rozkładu chi-kwadrat dla *k*-1 stopni swobody, gdzie *k* to liczność grup.

Następnie na podstawie wartości *H* oraz liczby stopni swobody wyliczana jest wartość *p*. Jeśli jest ona większa niż 0,05, oznacza to, przynajmniej jedna z grup różni się istotnie od pozostałych.

Podobnie jak w przypadku Anova, test ten wskazuje tylko różnice w jednej z grup, ale nie wskazuje w której. Aby tego dokonać, potrzeby jest test *post-hoc* np. test *Dunna*.

Rezultaty tych testów oraz testów post-hoc są opisane w rozdziale 3.3.

[31]Sztos IT, Post Hoc Tukeya, https://sztos-it.com/wzory_statystyczne_analiza_post_hoc_tukeya.html (dostęp: 06.09.2025).
[32]P. Iwankowski, *Test Kruskala-Wallisa.* https://pogotowiestatystyczne.pl/slowniki/test-kruskala-wallisa/ (dostęp: 06.09.2025).

3.1.6. Dunna

Jest Testem *post-hoc* do znajdowania różnic pomiędzy konkretnymi obserwacjami.

Jak podaje pqstst.pl „Test *Dunna* zawiera poprawkę na rangi wiązane i jest testem korygowanym ze względu na wielokrotne testowanie. Najczęściej wykorzystuje się tu korektę *Bonferroniego* lub *Sidaka*”[33]

Schemat działania:

Ustalenie hipotezy H_0 wskazującą na brak różnic między medianami w sprawdzanych grupach. Podobnie jak w teście *Kruskala-Wallisa* wszystkie obserwacje zostają uszeregowane oraz przypisuje się im rangi.

Następnie dla każdej z par obliczana jest statystyka *Z.* Później z tablic rozkładu normalnego obliczana jest wartość prawdopodobieństwa *p.* W kolejnym kroku stosuje się poprawką *Bonferroniego*.
Na koniec jeśli wartość p jest mniejsza od 0,05, oznacza to, że sprawdzana para posiada istotną statystycznie różnicę.

W obu przeprowadzonych badaniach ze względu na wielkość błędu typu pierwszego korekta *Bonferroniego* wyniosła 0,005.

[33] *Testy nieparametryczne*, 2014, https://manuals.pqstat.pl/statpqpl:porown3grpl:nparpl (dostęp: 06.09.2025).

3.2. Wyniki badań

Dane w zestawianiach zostały przedstawione jako średnie z odchyleniem standardowym próbki. Dodatkowo dane zostały przedstawione również w postaci wykresów pudełkowych. Wszystkie testy statystyczne zostały przeprowadzone z użyciem narzędzi na stronie https://www.statskingdom.com.

3.2.1. Wyniki zebrane za pomocą programu

Dane dla przypadku gdy walidacja jest w trakcie wczytywania danych:

Tab. 1. Przedstawiająca średnie oraz odchylenia standardowe danych pochodzące z napisanego programu dla przypadku, gdy walidacja jest w trakcie wczytywania pliku.

Algorytm	Rozmiar pliku [MB]	Średni czas [ms]	Odch. std. czasu [ms]	Średnia pamięć [MB]	Odch. std. pamięci [MB]
BufferedReader	100	1,21	0,01	1 364,89	249,57
CSVReader	100	1,54	0,04	1 271,41	191,66
FileReader	100	1,26	0,03	1 343,61	213,09
FilesLines	100	1,24	0,02	1 296,80	234,55
Scanner	100	1,58	0,02	1 877,24	345,90
BufferedReader	250	3,39	0,06	1 567,90	387,02
CSVReader	250	4,12	0,06	1 893,38	283,11
FileReader	250	3,39	0,07	1 778,80	286,30
FilesLines	250	3,37	0,04	1 784,59	489,96
Scanner	250	4,37	0,06	2 268,52	148,03
BufferedReader	500	7,04	0,09	2 824,44	433,27
CSVReader	500	8,57	0,10	2 779,14	387,72
FileReader	500	7,16	0,13	2 859,47	431,07
FilesLines	500	7,13	0,09	3 184,94	161,32
Scanner	500	8,89	0,08	2 908,32	547,96
BufferedReader	1000	15,18	0,27	4 814,11	409,51
CSVReader	1000	18,33	0,31	4 814,24	316,65
FileReader	1000	15,52	0,23	4 870,07	400,80
FilesLines	1000	15,36	0,36	4 817,92	388,62
Scanner	1000	19,03	0,29	6 134,54	332,20
BufferedReader	2000	33,53	0,65	9 150,79	555,78
CSVReader	2000	39,96	0,76	8 873,21	340,57
FileReader	2000	33,98	0,92	8 986,49	252,83
FilesLines	2000	33,49	0,95	9 104,64	414,44
Scanner	2000	40,65	0,45	9 126,64	580,67
BufferedReader	4000	71,21	0,91	16 522,89	149,76
CSVReader	4000	85,34	1,96	16 573,30	220,84
FileReader	4000	73,62	1,87	16 410,09	140,44
FilesLines	4000	72,12	1,28	16 355,65	79,58
Scanner	4000	86,71	0,88	16495,58	180,38

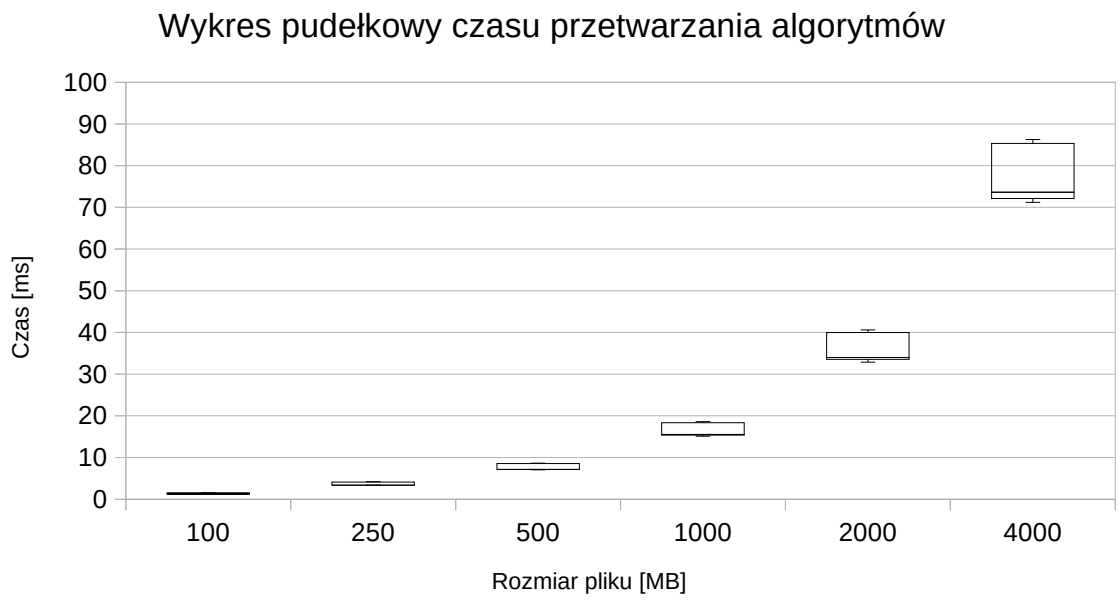

Wyk. 1. Przedstawiający wykres pudełkowy czasu prztwarzania algorytmów z walidacją w trakcie wczytywania pliku.

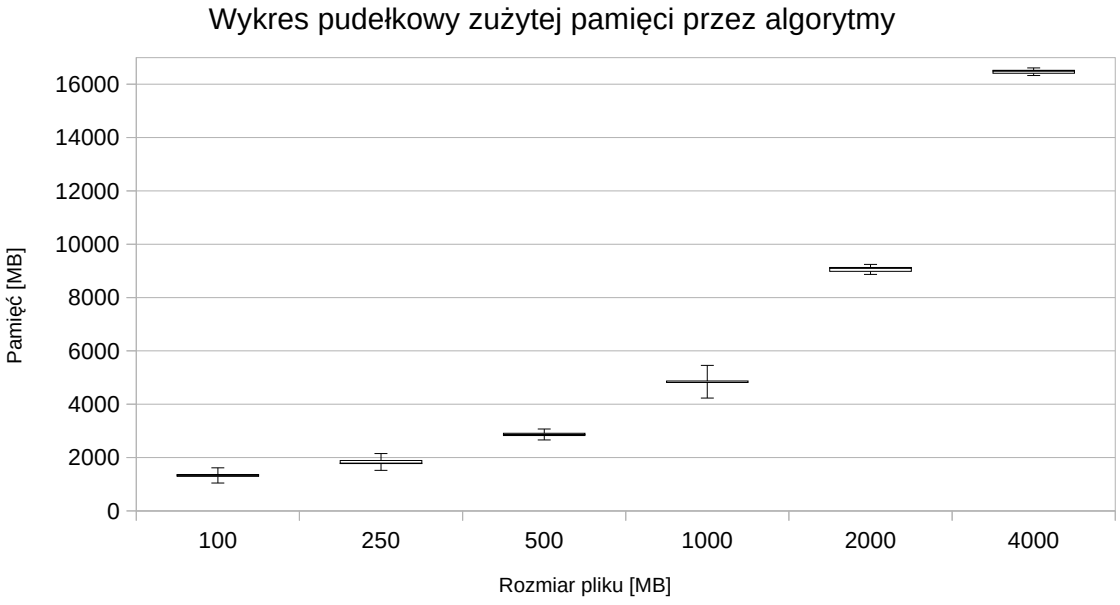

Wyk. 2. Przedstawiający wykres pudełkowy zużytej przez algorytmy pamięci z walidacją w trakcie wczytywania pliku.

Dane dla przypadku, gdy walidacja była po wczytaniu danych:

Tab. 2. Przedstawiająca średnie oraz odchylenia standardowe danych pochodzące z napisanego programu dla przypadku, gdy walidacja jest po wczytaniu pliku.

Algorytm	Rozmiar pliku [MB]	Średni czas [ms]	Odch. std czasu [ms]	Średnia Pamięć [MB]	Odch. std pamięci [MB]
BufferedReader	100	1,29	0,04	1 776,08	71,76
CSVReader	100	2,09	0,02	1 678,14	304,70
FileReader	100	1,48	0,05	1 658,36	124,51
FilesLines	100	1,33	0,07	1 739,10	99,10
Scanner	100	1,67	0,06	1 786,08	131,96
BufferedReader	250	3,55	0,08	1 776,08	71,76
CSVReader	250	5,44	0,07	2 272,85	490,96
FileReader	250	3,96	0,07	2 251,01	256,00
FilesLines	250	3,57	0,09	1 920,94	281,74
Scanner	250	4,41	0,07	2 280,80	377,18
BufferedReader	500	7,60	0,15	3 296,17	430,49
CSVReader	500	11,35	0,14	3 186,26	342,12
FileReader	500	8,55	0,18	3 254,55	371,65
FilesLines	500	7,64	0,16	3 332,43	503,77
Scanner	500	9,33	0,08	3 287,51	347,56
BufferedReader	1000	16,26	0,32	5 984,33	595,82
CSVReader	1000	23,95	0,29	5 622,13	781,81
FileReader	1000	18,26	0,28	5 678,65	783,84
FilesLines	1000	16,43	0,32	6 083,24	349,28
Scanner	1000	19,88	0,15	5 576,37	569,07
BufferedReader	2000	34,67	0,29	10 276,34	864,32
CSVReader	2000	50,36	0,62	10 510,77	702,20
FileReader	2000	38,28	0,58	10 279,93	502,42
FilesLines	2000	34,91	0,31	10 366,53	707,22
Scanner	2000	41,66	0,40	10 082,20	432,90
BufferedReader	4000	82,05	1,02	16 255,76	352,00
CSVReader	4000	113,39	1,39	16 269,32	476,81
FileReader	4000	89,07	1,86	16 276,49	369,83
FilesLines	4000	82,38	1,68	16 296,43	388,33
Scanner	4000	96,86	1,84	16 530,40	158,68

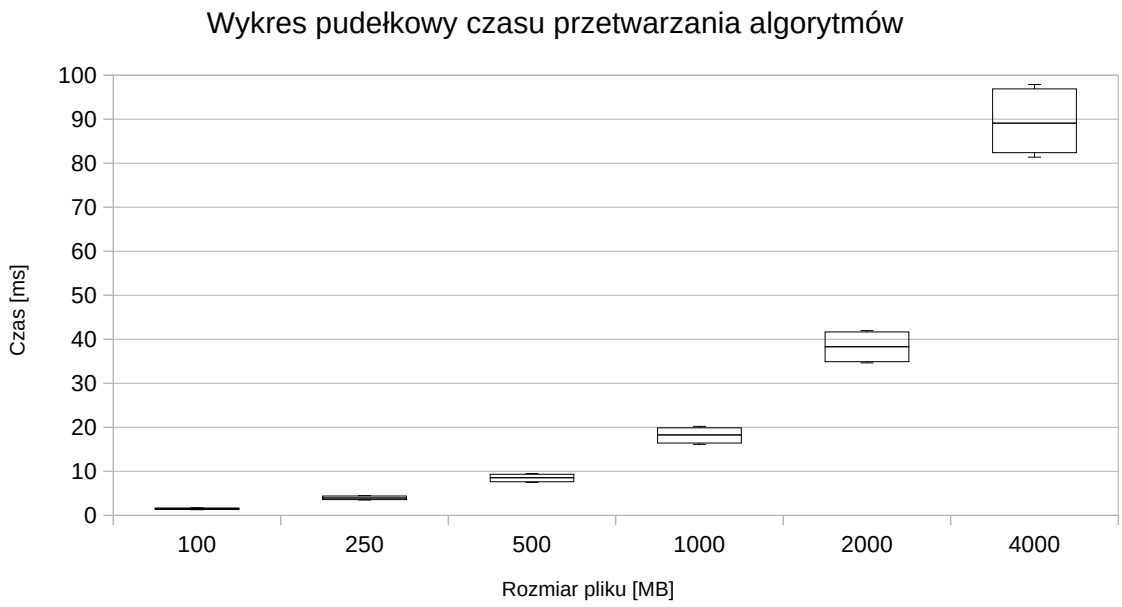

Wyk. 3. Przedstawiający wykres pudełkowy czasu prztwarzania algorytmów z walidacją po wczytywaniu pliku.

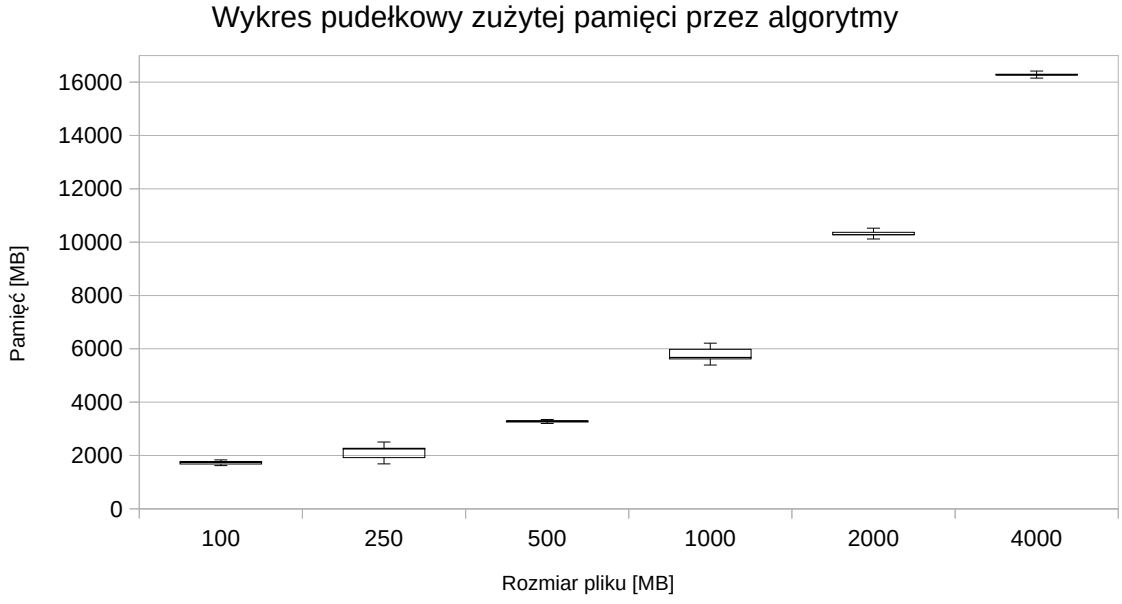

Wyk. 4. Przedstawiający wykres pudełkowy zużytej przez algorytmy pamięci z walidacją po wczytywaniu pliku.

3.2.2. Dane zebrane za pomocą narzędzia Profiler

Dane dla przypadku gdy walidacja jest w trakcie wczytywania danych:

Tab. 3 Przedstawiająca średnie oraz odchylenia standardowe danych pochodzące z narzędzia Profiler dla przypadku, gdy walidacja jest w trakcie wczytywania pliku (1/2).

Algorytm	Rozmiar pliku [MB]	Czas całkowity [ms]	Odch. std czasu [ms]	Czas wczytywania [ms]	Odch. std czasu [ms]
BufferedReader	100	1,46	0,04	0,44	0,15
CSVReader	100	1,82	0,10	0,70	0,03
FileReader	100	1,64	0,04	0,61	0,09
FilesLines	100	1,54	0,09	0,48	0,08
Scanner	100	1,74	0,05	0,80	0,09
BufferedReader	250	3,40	0,07	1,01	0,02
CSVReader	250	4,07	0,03	1,79	0,05
FileReader	250	3,59	0,03	1,25	0,07
FilesLines	250	3,30	0,02	1,01	0,11
Scanner	250	4,29	0,04	1,85	0,04
BufferedReader	500	6,57	0,03	1,75	0,04
CSVReader	500	8,20	0,04	3,63	0,12
FileReader	500	7,66	0,46	2,85	0,31
FilesLines	500	6,68	0,13	1,98	0,23
Scanner	500	8,42	0,09	3,74	0,05
BufferedReader	1000	13,45	0,45	3,47	0,06
CSVReader	1000	17,07	0,37	7,15	0,01
FileReader	1000	14,81	0,34	4,62	0,13
FilesLines	1000	13,79	0,44	3,96	0,37
Scanner	1000	16,88	0,31	7,09	0,12
BufferedReader	2000	29,64	0,73	7,80	0,58
CSVReader	2000	35,94	0,53	14,63	0,40
FileReader	2000	32,25	1,13	10,26	1,61
FilesLines	2000	29,61	0,87	7,96	0,28
Scanner	2000	35,79	0,10	14,46	0,35
BufferedReader	4000	65,92	3,05	15,98	0,51
CSVReader	4000	77,91	0,51	29,62	0,21
FileReader	4000	67,25	1,12	19,88	0,49
FilesLines	4000	59,65	2,49	15,05	0,96
Scanner	4000	72,72	2,27	27,05	1,57

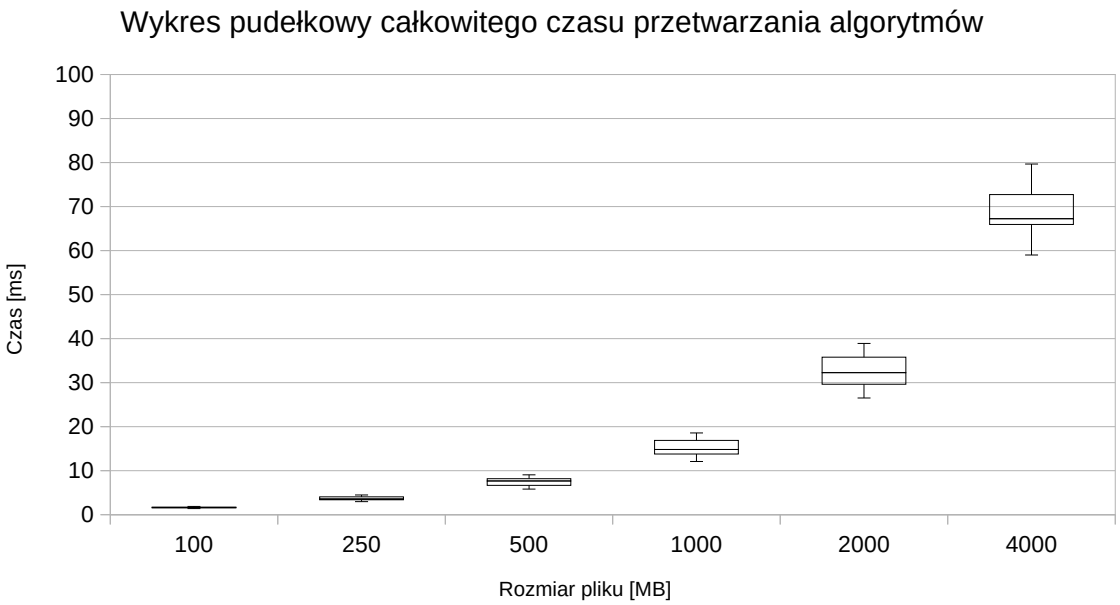

Wyk. 5. Przedstawiający wykres pudełkowy całkowitego czasu prztwarzania algorytmów z walidacją w trakcie wczytywania pliku, dla danych narzędzia Profiler.

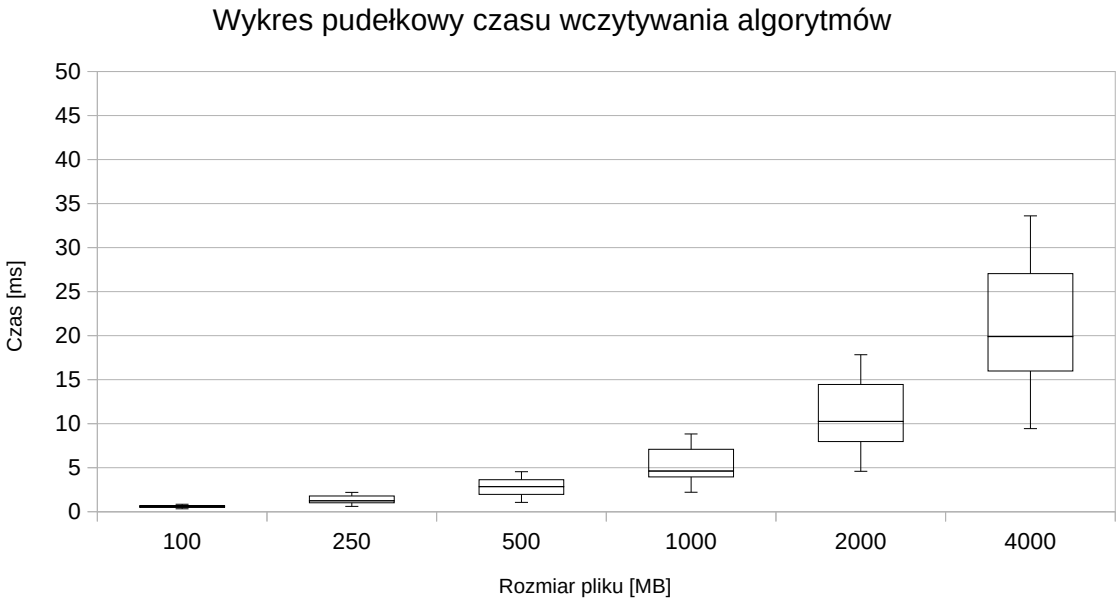

Wyk. 6. Przedstawiający wykres pudełkowy czasu wczytywania algorytmów z walidacją w trakcie wczytywania pliku, dla danych narzędzia Profiler.

Tab. 4 Przedstawiająca średnie oraz odchylenia standardowe danych pochodzące z narzędzia Profiler dla przypadku, gdy walidacja jest w trakcie wczytywania pliku (2/2).

Algorytm	Rozmiar pliku [MB]	Czas walidacji [ms]	Odch. std czasu [ms]	Całkowita zaalokowana pamięć [GB]	Odch. std pamięci [GB]
BufferedReader	100	1,01	0,16	1,77	0,01
CSVReader	100	1,12	0,13	1,68	0,00
FileReader	100	1,03	0,08	1,68	0,00
FilesLines	100	1,07	0,04	1,76	0,01
Scanner	100	0,95	0,04	2,26	0,01
BufferedReader	250	2,39	0,06	4,38	0,01
CSVReader	250	2,29	0,04	4,16	0,01
FileReader	250	2,34	0,09	4,13	0,00
FilesLines	250	2,29	0,11	4,38	0,00
Scanner	250	2,43	0,01	5,58	0,01
BufferedReader	500	4,81	0,07	8,75	0,00
CSVReader	500	4,57	0,13	8,30	0,01
FileReader	500	4,81	0,16	8,24	0,00
FilesLines	500	4,69	0,10	8,75	0,00
Scanner	500	4,68	0,06	11,14	0,00
BufferedReader	1000	9,98	0,51	17,49	0,00
CSVReader	1000	9,92	0,36	16,58	0,00
FileReader	1000	10,19	0,38	16,48	0,02
FilesLines	1000	9,83	0,21	17,46	0,02
Scanner	1000	9,79	0,41	22,28	0,03
BufferedReader	2000	21,84	0,63	34,97	0,05
CSVReader	2000	21,31	0,36	33,19	0,00
FileReader	2000	21,99	0,67	32,92	0,01
FilesLines	2000	21,66	0,60	34,94	0,05
Scanner	2000	21,33	0,41	44,63	0,00
BufferedReader	4000	49,94	3,18	69,73	0,11
CSVReader	4000	48,29	0,49	66,18	0,01
FileReader	4000	47,37	0,83	65,80	0,01
FilesLines	4000	44,61	1,58	69,73	0,10
Scanner	4000	45,68	0,71	89,05	0,00

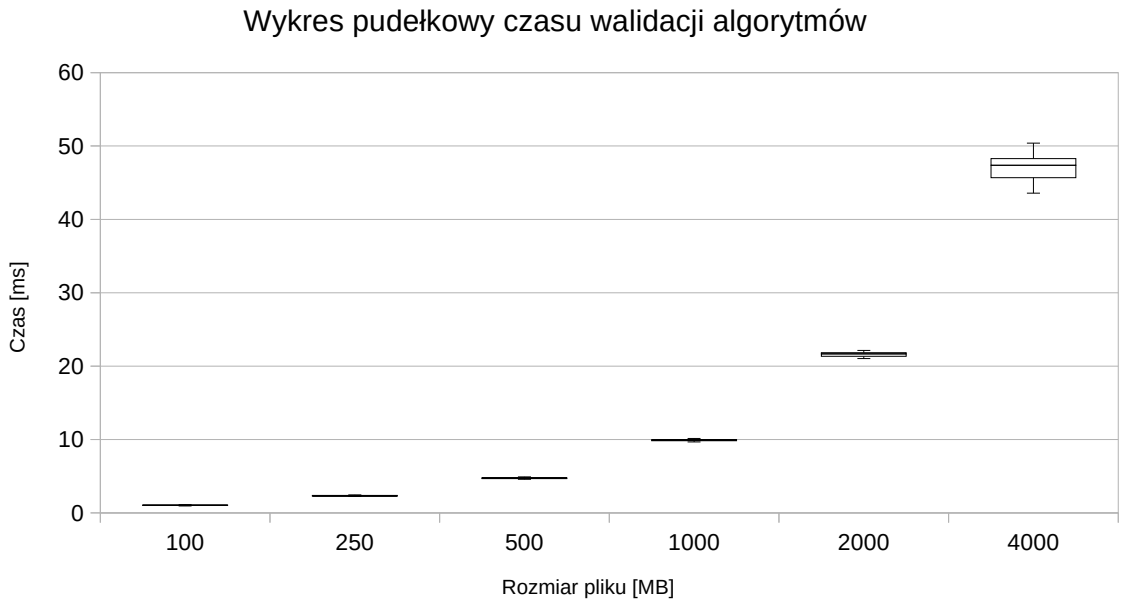

Wyk. 7. Przedstawiający wykres pudełkowy czasu walidacji algorytmów z walidacją w trakcie wczytywania pliku, dla danych z narzędzia Profiler.

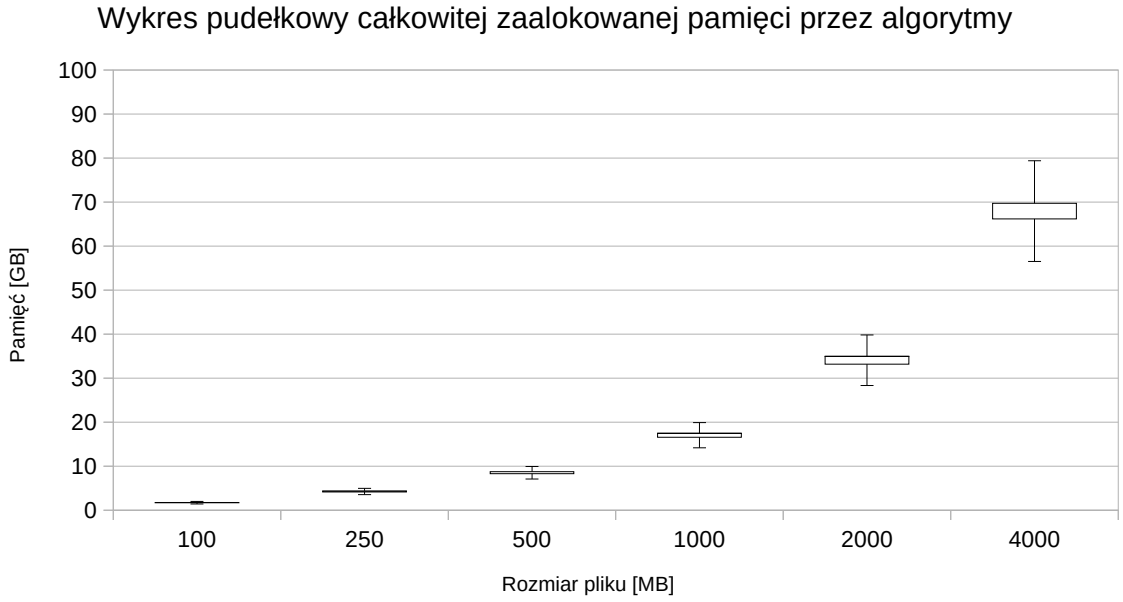

Wyk. 8. Przedstawiający wykres pudełkowy całkowitej zaalokowanej pamięci przez algorytmy z walidacją w trakcie wczytywania pliku, dla danych z narzędzia Profiler.

Dane dla przypadku gdy walidacja następuje po wczytaniu danych:

Tab. 5 Przedstawiająca średnie oraz odchylenia standardowe danych pochodzące z narzędzia Profiler dla przypadku, gdy walidacja jest po wczytaniu pliku (1/2).

Algorytm	Rozmiar pliku [MB]	Czas całkowity [ms]	Odch. std czasu [ms]	Czas wczytywania [ms]	Odch. std czasu [ms]
BufferedReader	100	1,57	0,06	0,54	0,07
CSVReader	100	2,12	0,07	1,22	0,15
FileReader	100	1,71	0,07	0,66	0,06
FilesLines	100	1,58	0,03	0,47	0,08
Scanner	100	1,92	0,05	0,89	0,03
BufferedReader	250	3,37	0,07	1,19	0,06
CSVReader	250	5,34	0,09	2,98	0,13
FileReader	250	3,68	0,25	1,25	0,07
FilesLines	250	3,45	0,06	1,08	0,20
Scanner	250	4,38	0,10	1,88	0,08
BufferedReader	500	6,74	0,07	2,05	0,15
CSVReader	500	10,54	0,15	5,76	0,15
FileReader	500	7,58	0,07	2,77	0,26
FilesLines	500	6,78	0,17	2,13	0,19
Scanner	500	8,54	0,27	3,77	0,08
BufferedReader	1000	14,44	0,20	4,27	0,25
CSVReader	1000	21,55	0,31	11,55	0,22
FileReader	1000	16,28	0,34	6,08	0,48
FilesLines	1000	14,34	0,27	4,22	0,15
Scanner	1000	18,05	0,20	7,42	0,12
BufferedReader	2000	30,90	0,63	8,60	0,18
CSVReader	2000	46,03	1,02	23,08	0,64
FileReader	2000	33,90	1,95	11,96	0,58
FilesLines	2000	30,52	1,16	8,68	0,40
Scanner	2000	37,40	0,65	15,21	0,50
BufferedReader	4000	65,91	0,52	17,65	0,29
CSVReader	4000	96,32	0,29	47,96	0,75
FileReader	4000	72,91	0,61	24,93	0,15
FilesLines	4000	67,67	0,65	18,42	1,14
Scanner	4000	78,27	3,39	30,54	1,01

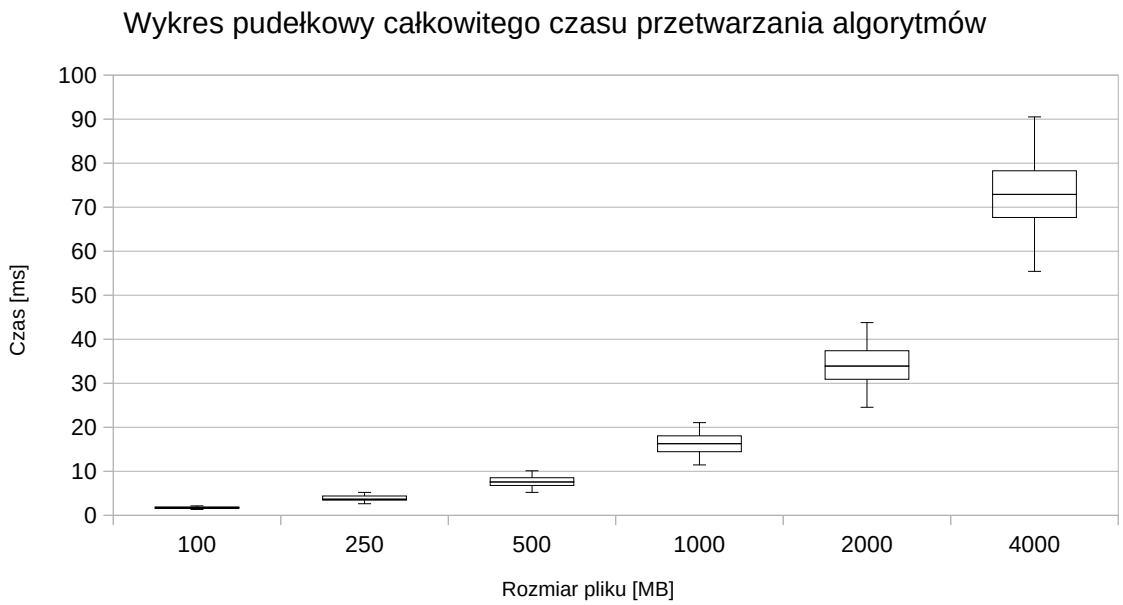

Wyk. 9. Przedstawiający wykres pudełkowy całkowitego czasu prztwarzania algorytmów z walidacją po wczytywaniu pliku, dla danych z narzędzia Profiler.

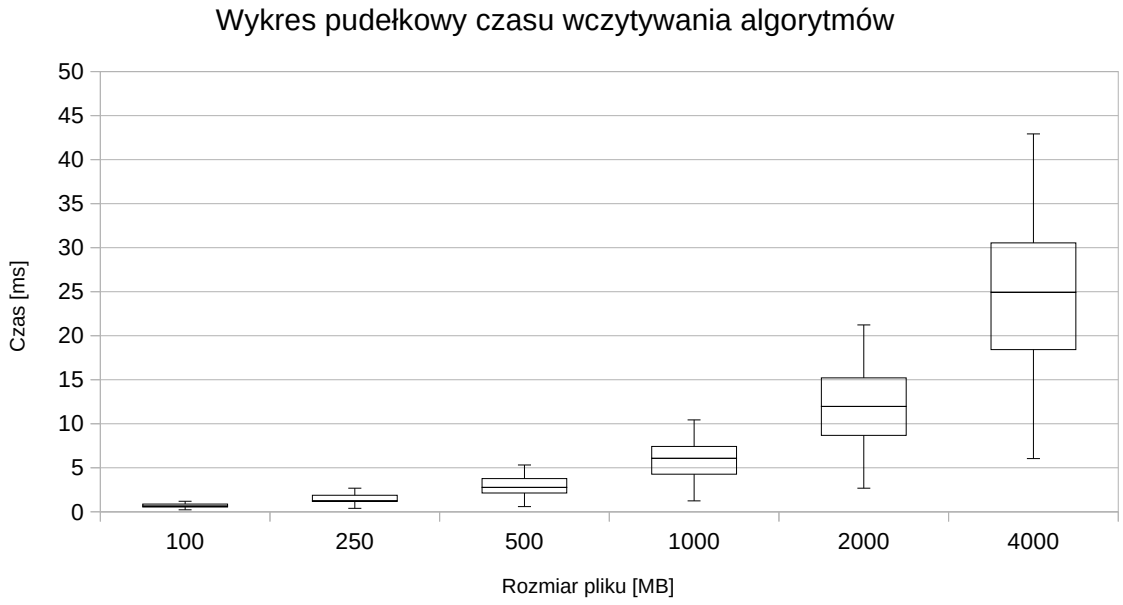

Wyk. 10. Przedstawiający wykres pudełkowy czasu wczytywania algorytmów z walidacją po wczytywaniu pliku, dla danych z narzędzia Profiler.

Tab. 6 Przedstawiająca średnie oraz odchylenia standardowe danych pochodzące z narzędzia Profiler dla przypadku, gdy walidacja jest po wczytaniu pliku (2/2).

Algorytm	Rozmiar pliku [MB]	Czas walidacji [ms]	Odch. std czasu [ms]	Całkowita zaalokowana pamięć [GB]	Odch. std pamięci [GB]
BufferedReader	100	1,03	0,01	1,81	0,01
CSVReader	100	0,93	0,03	2,85	0,01
FileReader	100	1,05	0,02	1,89	0,01
FilesLines	100	1,12	0,05	1,81	0,01
Scanner	100	1,04	0,05	2,32	0,07
BufferedReader	250	2,18	0,03	4,50	0,01
CSVReader	250	2,37	0,10	7,10	0,01
FileReader	250	2,28	0,01	4,72	0,01
FilesLines	250	2,36	0,14	4,46	0,07
Scanner	250	2,50	0,02	5,83	0,11
BufferedReader	500	4,69	0,19	8,96	0,01
CSVReader	500	4,78	0,14	14,17	0,01
FileReader	500	4,81	0,22	9,38	0,01
FilesLines	500	4,65	0,15	8,96	0,01
Scanner	500	4,78	0,20	11,50	0,23
BufferedReader	1000	10,18	0,29	17,91	0,02
CSVReader	1000	10,01	0,09	28,34	0,03
FileReader	1000	10,20	0,16	18,74	0,02
FilesLines	1000	10,12	0,32	17,91	0,01
Scanner	1000	10,63	0,16	22,98	0,45
BufferedReader	2000	22,40	0,41	35,92	0,05
CSVReader	2000	22,95	0,38	56,69	0,01
FileReader	2000	21,95	1,37	37,52	0,05
FilesLines	2000	21,84	0,97	35,89	0,05
Scanner	2000	22,19	0,20	46,00	0,88
BufferedReader	4000	48,26	0,71	71,79	0,00
CSVReader	4000	48,36	0,67	113,43	0,01
FileReader	4000	47,98	0,49	74,94	0,13
FilesLines	4000	49,25	1,68	71,59	0,34
Scanner	4000	47,70	2,44	90,92	0,12

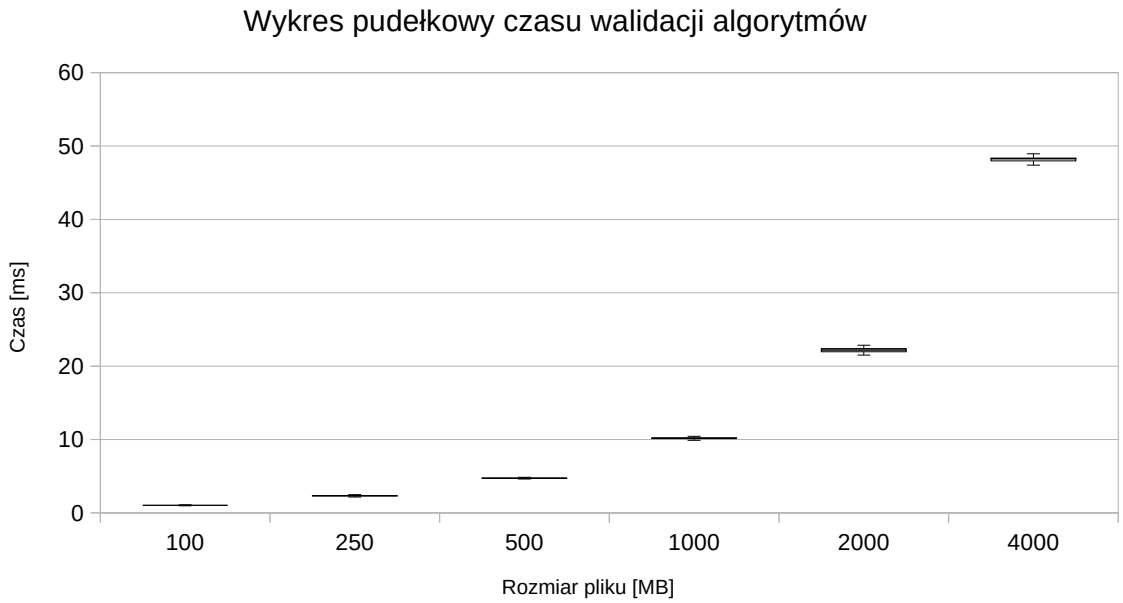

Wyk. 11. Przedstawiający wykres pudełkowy czasu walidacji algorytmów z walidacją po wczytywaniu pliku dla danych z narzędzia Profiler.

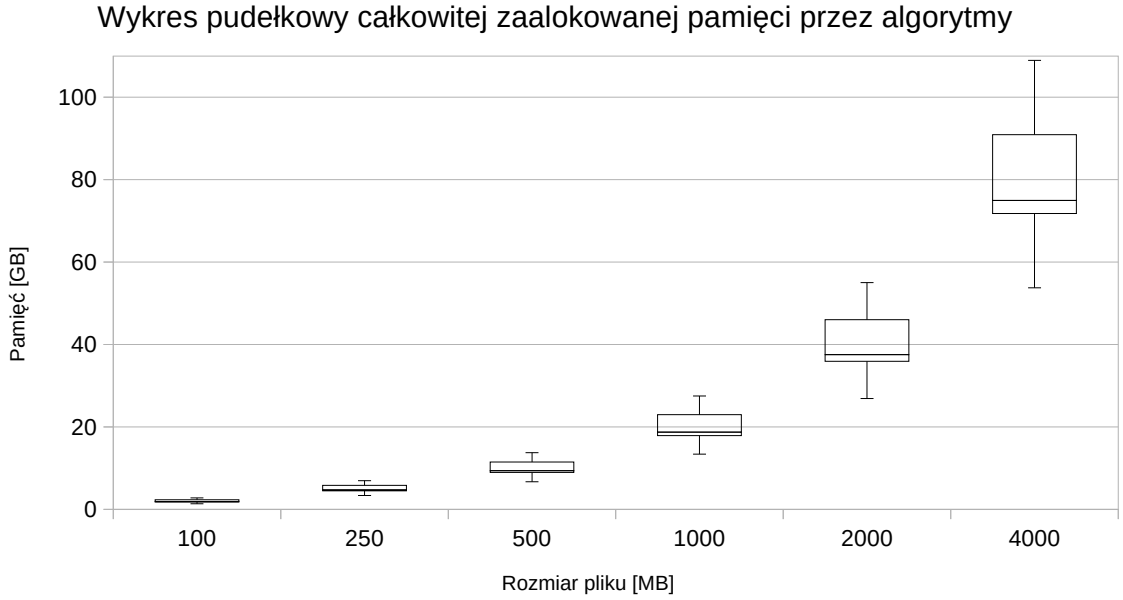

Wyk. 12. Przedstawiający wykres pudełkowy całkowitej zaalokowanej pamięci przez algorytmy z walidacją po wczytywaniu pliku dla danych z narzędzia Profiler.

3.3. Wykresy

W tej części w sposób wizualny zostały przedstawione dane zawarte we wcześniejszym podrozdziale. Na wykresach tych łatwo można dostrzec różnice i wytypować lepsze i gorsze rozwiązania. Opisy wskazują również, które z różnic są istotne statystycznie.

3.3.1. Wyniki zebrane za pomocą programu

Wykresy przestawiające czas działania w zależności od rozmiaru plików dla poszczególnych algorytmów:

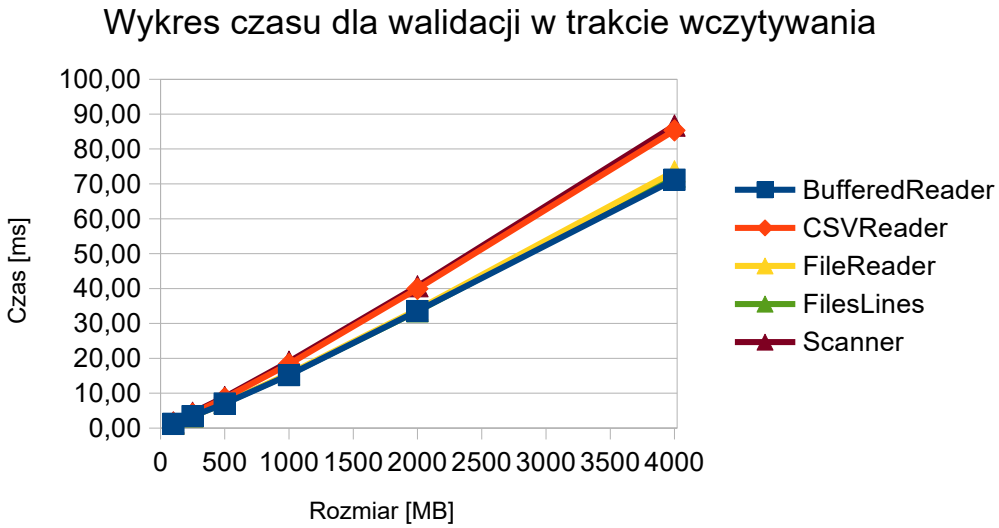

Wyk. 13. Przedstawiający zależność czasu od rozmiaru dla przypadku, gdy walidacja odbywa się w trakcie wczytywania.

Na wykresie pierwszym widać, że najlepszy czas uzyskały algorytmy oparte o *BufferedReader* oraz *FilesLines*. Natomiast najgorszy czas uzyskały *CSVReader* oraz *Scanner*. W żadnym z przypadków pomiędzy dwoma najszybszymi rozwiązaniami nie występują istotne statystycznie różnice. Co za tym idzie, nie można jednoznacznie wskazać, który z tych dwóch podejść jest wydajniejsze pod względem czasu. Efekt istotnie statystycznie, pojawiają się pomiędzy dwoma pierwszymi a kolejnym algorytmem, czyli *FileReader*. Pomiędzy 2 najwolniejszymi rozwiązaniami istotna różnica jest do pliku o wielkości 1GB. Szybszy w tych przypadkach jest *CSVReader*, nad *Scannerem*. Powyżej tej granicy nie można jednoznacznie wskazać najwolniejszego algorytmu.

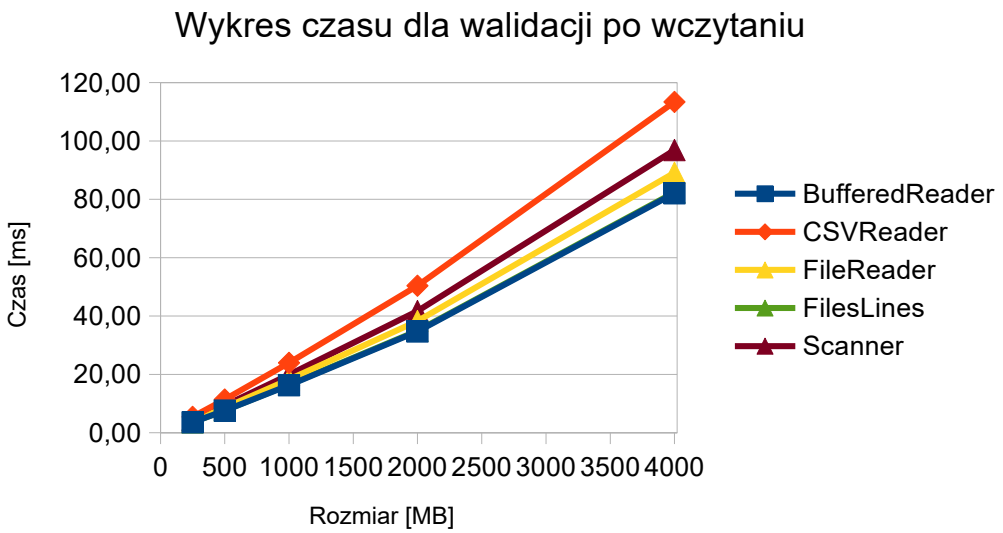

Wyk. 14. Przedstawiający zależność czasu od rozmiaru dla przypadku, gdy walidacja odbywa się w trakcie wczytywania.

W przypadku opóźnionej walidacji ponownie najszybszymi algorytmami są *BufferedReader* oraz *FilesLines* i ponownie nie istnieje statystycznie istotna różnica pomiędzy tymi algorytmami. Natomiast wszystkie pozostałe przypadki są na tyle zróżnicowane, że każde różnice są potwierdzone analizą statystyczną. Kolejnymi podejścia to: *FileReader*, *Scanner* oraz najwolniejszy ze stawki *CSVReader*.

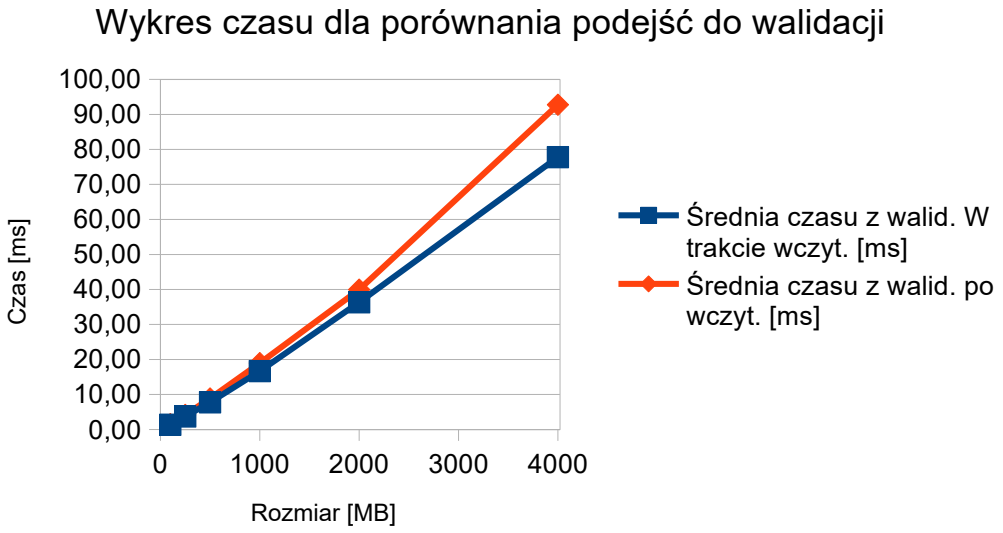

Wyk. 15. Przedstawiający zależność czasu od rozmiaru dla porównania średnich czasów pomiędzy podejściami do walidacji.

Wykres, który przedstawia średnie z 5 algorytmów z walidacją w trakcie wczytywania oraz z walidacją po wczytaniu całego pliku, aby w lepszy sposób ukazać różnicę w czasie pomiędzy tymi podejściami do walidacji.

Wykresy przedstawiające zużycie pamięci podczas działania w zależności od rozmiaru pliku dla poszczególnych algorytmów:

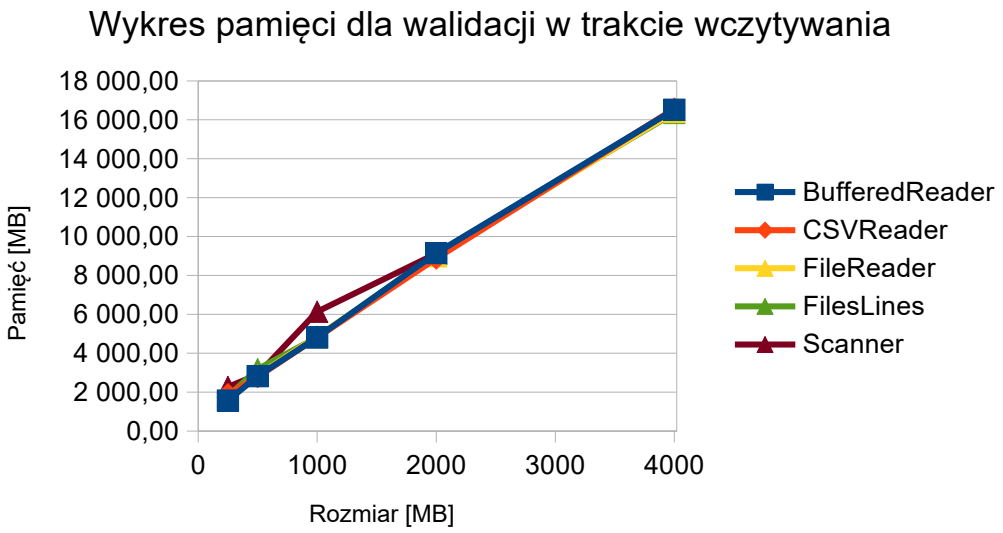

Wyk. 16. Przedstawiający zależność pamięci od rozmiaru dla przypadku, gdy walidacja odbywa się w trakcie wczytywania.

W przypadku zużycia pamięci z walidacją podczas wczytywania, o różnicach możemy mówić tylko w przypadku *Scannera* i to w przypadkach 100MB, 250MB oraz 1000MB. W pozostałych przypadkach nie stwierdzono statystycznie żadnych różnic między algorytmami.

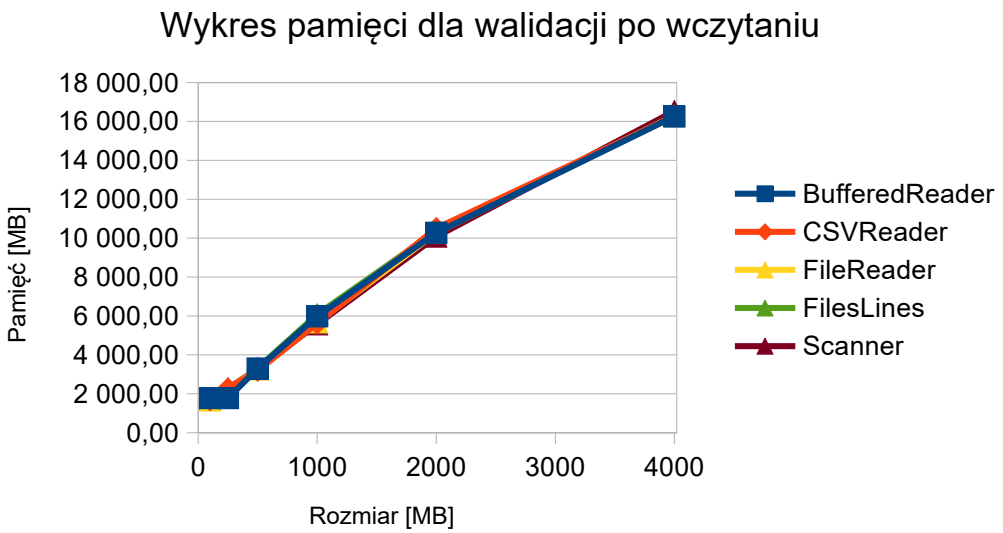

Wyk. 17. Przedstawiający zależność czasu od rozmiaru dla przypadku, gdy walidacja odbywa się po wczytywaniu pliku.

Zużycie pamięci z walidacją uruchomioną po zrealizowaniu operacji wejścia/wyjścia, było we wszystkich przypadkach równe pod względem statystycznym.

Porównując pamięć względem sposobu walidacji, okazuje się, że dla każdej próbki poniżej 4GB walidacja w trakcie wczytywania jest bardziej wydajna pamięciowo. W przypadku 4GB algorytmy z późniejszą walidacją są mocno organiczne przez limit pamięci operacyjnej dla programu, przez co wyniki są porównywalne.

3.3.2. Wyniki zebrane za pomocą narzędzia Profiler

Wykresy przestawiające poszczególne czasy działania w zależności od rozmiaru plików dla poszczególnych algorytmów:

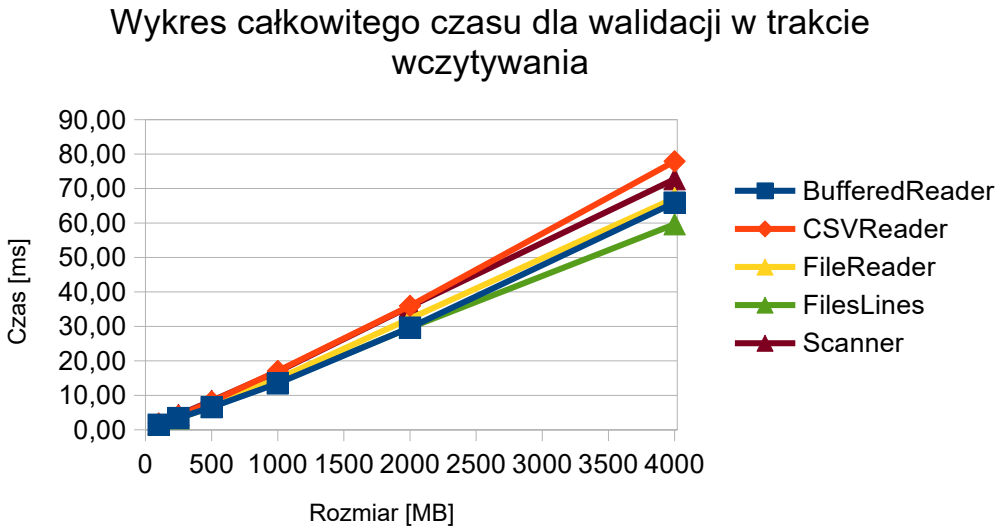

Wyk. 18. Przedstawiający zależność całkowitego czasu działania programu od rozmiaru dla przypadku, gdy walidacja odbywa się w trakcie wczytywania.

Na wykresie widać, że najmniej czasu na działanie potrzebował algorytm *FilesLines* oraz *BufferedReader*. Dla pliku 4GB istnieje statystycznie istotna różnica pomiędzy tymi algorytmami i można wskazać, że *FilesLines* przetworzył dane szybciej niż *BufferedReader*. Jednak dla pozostałych przypadków różnica była zbyt mała, aby jednoznacznie wskazać zwycięzcę.

FileReader we wszystkich przypadkach był w środku stawki, czasem współdzieląc miejsce z *BufferedReader* dla pliku 4GB lub z *CSVReader* oraz Scannerem dla pliku 100MB. Wymieniona dwójka najmniej wydajnych algorytmów tylko w przypadku pliku 1000MB miała istotną statystycznie różnicę w czasie działania. W tym przypadku lepszy okazał się Scanner nad *CSVReaderem*.

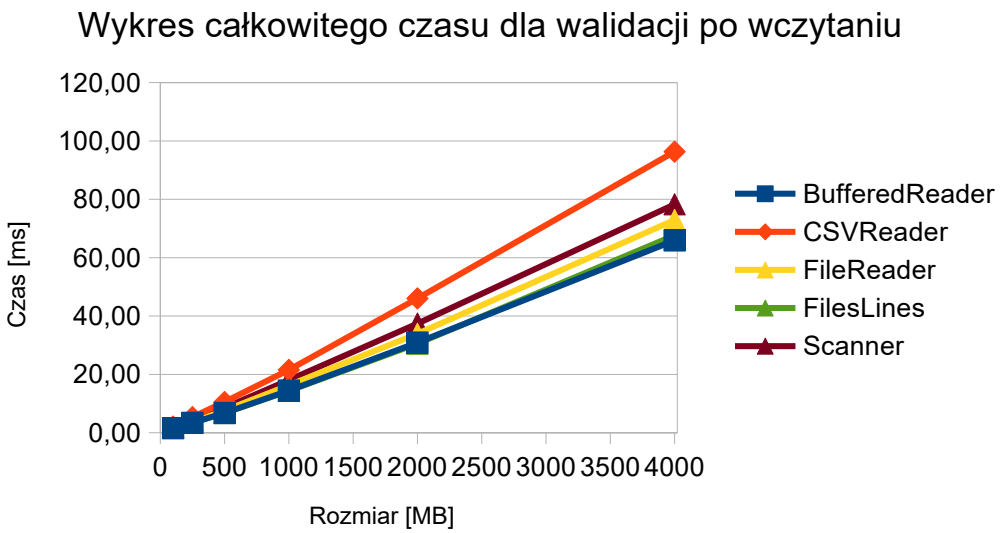

Wyk. 19. Przedstawiający zależność całkowitego czasu działania programu od rozmiaru dla przypadku, gdy walidacja następuję po wczytaniu pliku.

Najszybsza dwójka algorytmów tj. *BufferedReader* oraz *FilesLines* nie miała wystarczająco dużej różnicy między sobą, aby była statystycznie istotna.

Z kolei *FileReader* w przypadku 100MB oraz 250MB pliku również znajdował się na miejscu pierwszym. W każdym większym pliku był na miejscy 3 z istotną statystycznie różnicą między innymi algorytmami.

Kolejnym algorytmem jest *Scanner* w każdym przypadku zajmujący 4. miejsce oraz zawsze mający statystycznie istotne różnice do sąsiednich rozwiązań.

Najwolniejszym algorytmem potwierdzonym analizą dla każdego z plików okazał się *CSVReader.*

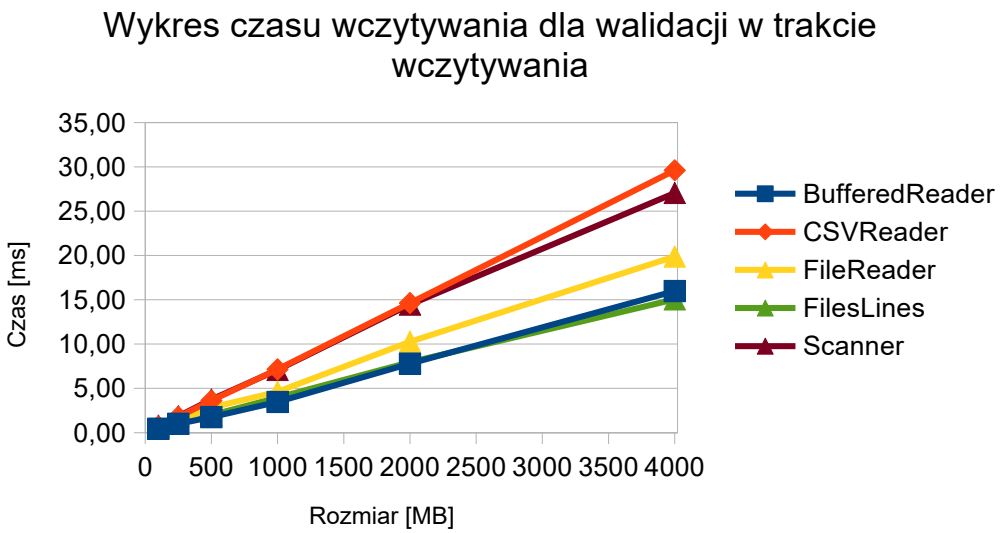

Wyk. 20. Przedstawiający zależność czasu trwania procesu samego wczytywania i obrabiania danych w programie od rozmiaru dla przypadku, gdy walidacja odbywa się w trakcie wczytywania.

Najistotniejsze i najdokładniejsze wyniki pokazuje właśnie wykres samego czasu wczytywania.

Najlepszymi algorytmami okazały się *BufferedReader* oraz *FilesLines* bez statystycznie istotnej różnicy między nimi, co oznacza, że nie można jednoznacznie wskazać jednego najszybszego algorytmu.

Dla pliku 100MB różnice były na tyle małe, że żadna para algorytmów nie ma istotnej statystycznie różnicy.

Środek stawki zajmuje *FileReader* w każdym przypadku (oprócz 100MB) mając istotną różnicę między sąsiednimi miejscami.

Natomiast różnica pomiędzy *Scannerem* a *CSVReaderem* tylko dla pliku 4000MB zachodzi efekt istotny statystycznie. W pozostałych przypadkach nie można stwierdzić dokładnej kolejności tych algorytmów.

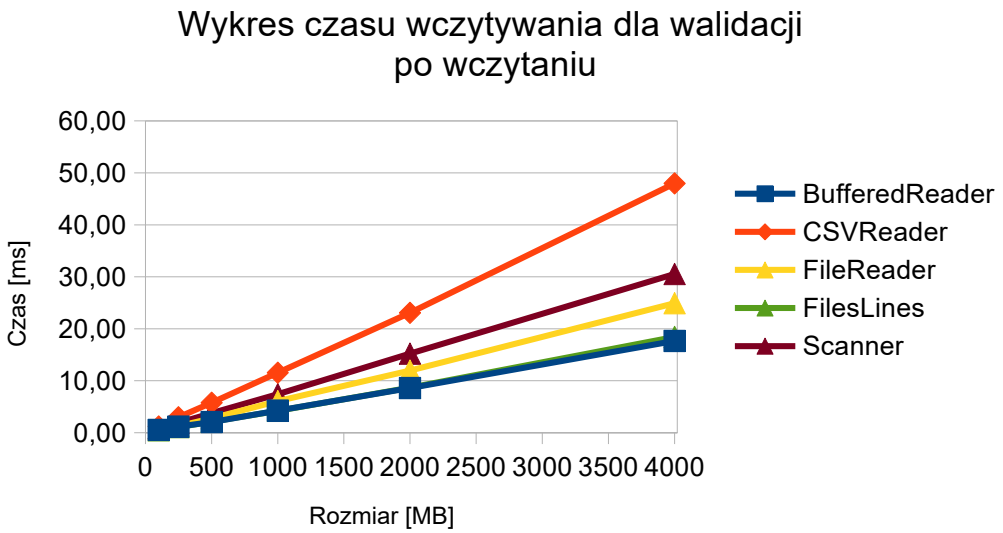

Wyk. 21. Przedstawiający zależność czasu trwania procesu samego wczytywania i obrabiania danych w programie od rozmiaru dla przypadku, gdy walidacja następuje po wczytaniu pliku.

Ponownie najlepszymi algorytmami okazały się *BufferedReader* oraz *FilesLines* bez statystycznie istotnej różnicy między nimi, co oznacza, że nie można jednoznacznie wskazać jednego najszybszego algorytmu.

Dla plików 100MB oraz 250MB na pierwszym miejscu znalazł się także *FileReader*. Dla większych plików różnica wzrosła na tyle, że jest ona potwierdzona analizą. Kolejnym algorytmem w zestawieniu jest *Scanner*, a zdecydowanie najgorszym okazał się *CSVReader*. Oba algorytmy mają istotne statystycznie różnice pomiędzy sobą jak i pozostałymi rozwiązaniami.

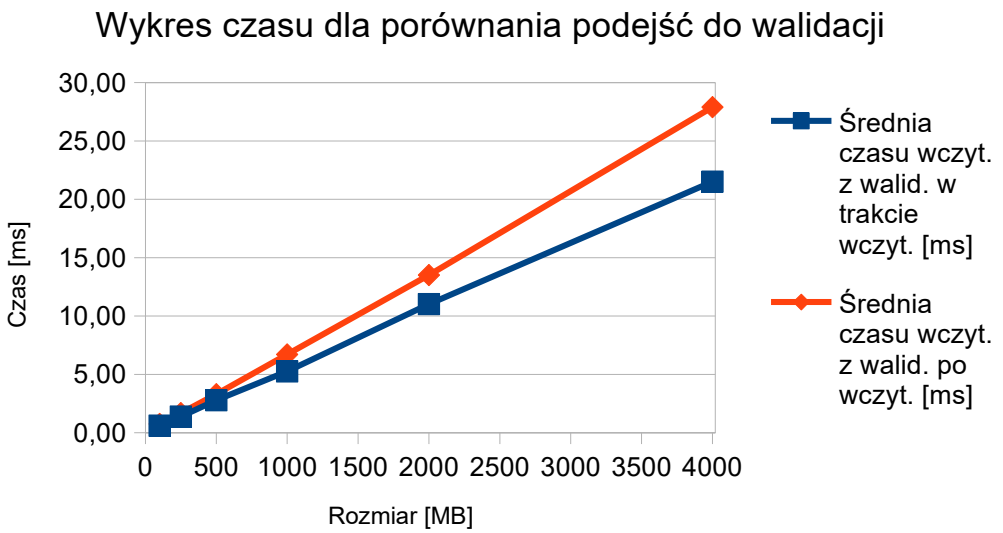

Wyk. 22. Przedstawiający zależność czasu samego wczytywania i obrabiania danych w programie od rozmiaru, dla porównania średnich czasów pomiędzy podejściami do walidacji.

Porównując oba podejścia do momentu walidacji, ewidentnie widać, że walidacja w trakcie wczytywania jest znacznie efektywniejsza pod względem czasu niżeli walidacja przeprowadzona po załadowaniu całego pliku do pamięci.

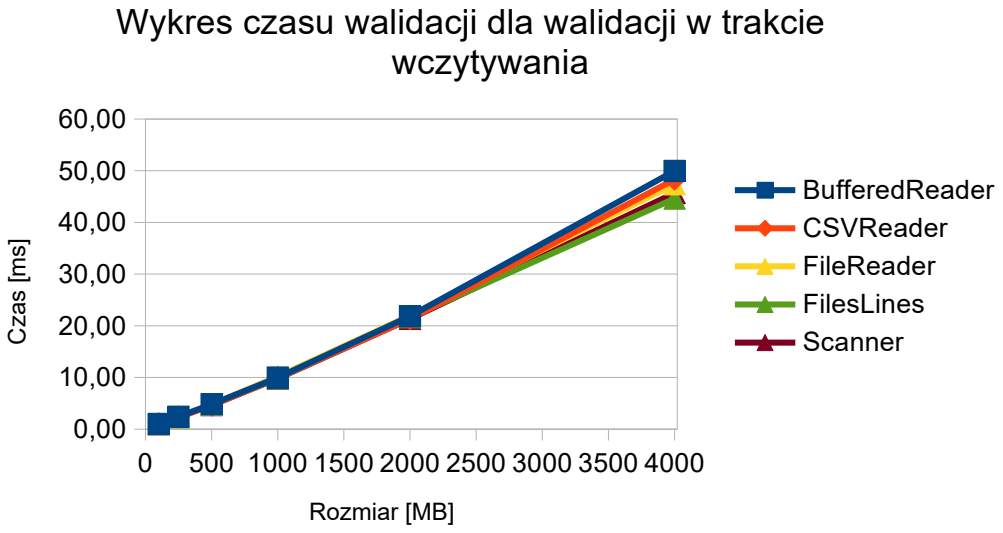

Wyk. 23. Przedstawiający zależność czasu trwania procesu walidacji w programie od rozmiaru dla przypadku, gdy walidacja odbywa się w trakcie wczytywania.

Zgodnie z oczekiwaniami czas samej walidacji plików jest pod względem statystycznym identyczny dla każdego rozmiaru pliku.

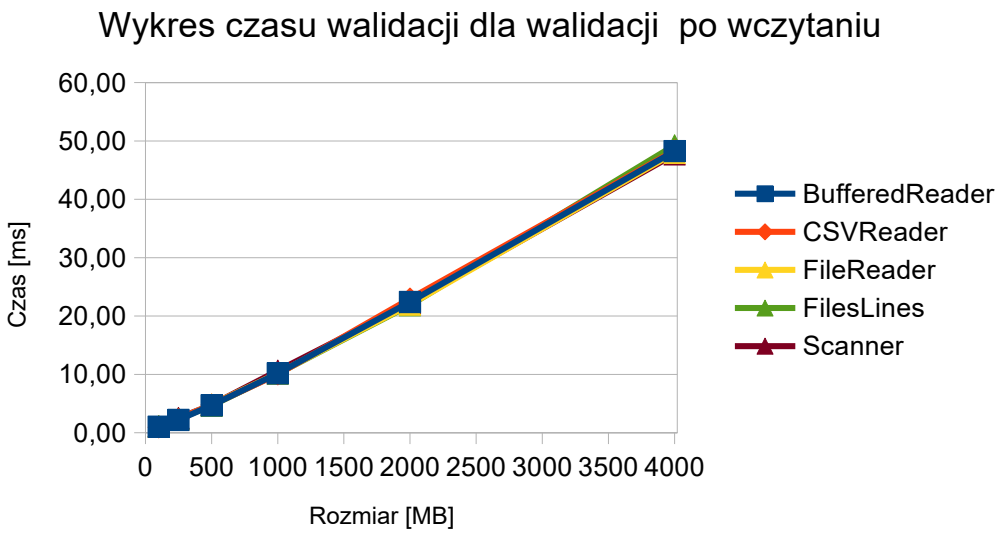

Wyk. 24. Przedstawiający zależność czasu trwania procesu walidacji w programie od rozmiaru dla przypadku, gdy walidacja następuje po wczytaniu pliku.

Podobnie jak w przypadku walidacji w trakcie wczytywania tutaj również czas walidacji jest równy pod względem statystycznym.

Wykresy przedstawiające całkowitą zaalokowaną pamięci podczas działania programu w zależności od rozmiaru pliku dla poszczególnych algorytmów:

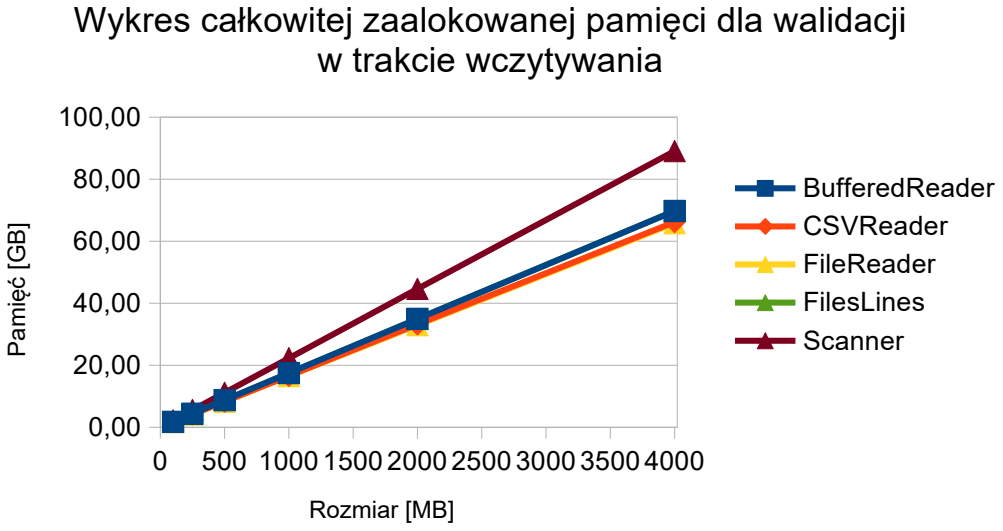

Wyk. 25. Przedstawiający zależność całkowitej zaalokowanej pamięci od rozmiaru dla przypadku, gdy walidacja odbywa się w trakcie wczytywania pliku.

Najmniej pamięci zaalokował algorytm *FileReader*, dzieląc pierwsze miejsce tylko w przypadku 100MB z *CSVReader'em*. W pozostałych przypadkach różnica między tą parą była istotna statystycznie.

W środku stawki znalazły się 2 algorytmy *BufferedReader* oraz *CSVReader*, które między sobą nie mają istotnej statystycznie różnicy, ale mają takowa pomiędzy sąsiednimi miejscami.
Niechlubne ostatnie miejsce i najwięcej zaalokowanej pamięci zajął *Scanner*.

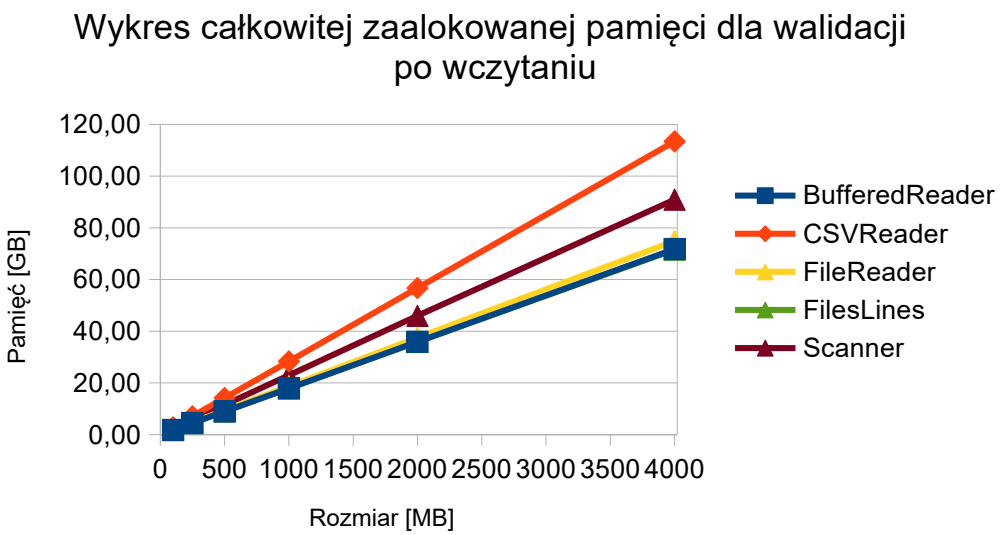

Wyk. 26. Przedstawiający zależność całkowitej zaalokowanej pamięci od rozmiaru dla przypadku, gdy walidacja następuje po wczytywaniu pliku.

Najmniej zaalokowanej pamięci przypadło dwóm algorytmom: *BufferedReader* oraz *FilesLines*. Różnica między nimi jest zbyt mała, aby można było wskazać faworyta. Dodatkowo dla pliku 100MB trzeci algorytm, czyli *FileReader* uzyskał taki sam wynik. Dla większych plików *FileReader* zajmował miejsce trzecie.

Czwarte miejsce przypadło podejściu *Scannera*. Algorytmem, który zaalokował najwięcej pamięci został *CSVReader*.

Wszystkie algorytmy z miejsc 3-5 miały między sąsiadującymi miejscami istotne statystycznie różnice.

3.4. Wnioski

Z przedstawionych badań wynika, że:

- Najszybszymi sposobami na wczytywanie i walidowanie plików w formacie *CSV* są algorytmy *BufferedReader* oraz *Files.lines()*. Różnica pomiędzy tymi podejściami była na tyle mała, że nie była ona istotna ze statycznego punktu widzenia, co za tym idzie, nie można jednoznacznie wskazać, który z wymieniony algorytmów był szybszym.

- Najwolniejszym algorytm w całym zestawieniu okazał się *CSVReader*. W niektórych przypadkach na końcu rankingu znajdował się także Scanner, szczególnie dla mniejszych z testowanych plików. Jednak to *CSVReader* w większych plikach radził sobie gorzej (lub równie słabo). Najgorsze wyniki notował przy walidacji po wczytaniu pliku. Wtedy znacząco odstawał od reszty.

- Porównanie walidacji przeprowadzanej w trakcie wczytywania było w każdym badanym przypadku, szybsze niż podejście, gdy walidacja następowała po zakończeniu wczytywania pliku do pamięci programu. Dodatkowo walidacja wykonywana po operacji wejścia/wyjścia była nieoptymalna pamięciowo, przez co następowało znaczące ograniczania wydajności algorytmu dla pliku 4GB, kiedy to program zajmował całą dostępną pamięć operacyjną, co skutkowało wzmożonym działaniem *Garbage Collector'a*.

- Algorytmem zużywającym najmniej pamięci w trakcie działania był *FileReader*. Wynik taki nie jest oczywisty, ponieważ dla większości przypadków zużywanie pamięci podczas pracy programu było takie samo. Jednak za taką decyzją przemawiają wyniki narzędzia *Profiler*, które to wskazują jakoby *FileReader* był algorytmem najwydajniejszym pod względem całkowitej zaalokowanej przez program pamięci.

- Dla wszystkich algorytmów z walidacją w trakcie wczytywania oraz po wczytaniu pliku można dopasować prostą, która dopasowuje się do wartości całkowitego czasu działania. Oznacza to, że zwiększenie rozmiaru pliku wpływa wprost proporcjonalnie do czasu jego przetwarzania. Jednak warto zwrócić uwagę, że w przypadku walidacji po wczytaniu pliku o rozmiarze 4GB, można zauważyć lekkie spowolnienie działania oraz zwiększenie nachylenia prostej regresji liniowej względem danych bez największej wartości.

- Do ograniczeń jakim zostały obarczone przeprowadzone badania należą między innymi:

    1. Zakres technologiczny ograniczający się do 5 algorytmów, możliwe jest istnienie wydajniejszego algorytmu, który nie został ujęty w tej pracy.
    2. Dane, jakie zostały wygenerowane trzymają się okraślonego formatu oraz są reprezentowane różne typy danych. Możliwe jest że dla innej struktury danych, poszczególne alorytmy zachowają się nieco inaczej.
    3. Testy były uruchamiane na jednej i tej samej platformie testowej. Na innych serwerach zachowanie może ulec zmianie.
    4. Badania skupiały się na działaniu jednowątkowym. Zrównoleglenie procesu mogło by przynieść odmienne rezultaty.
    5. Ograniczenie pamięci do 16 GB i co za tym idzie przetwarzanie plików do 4GB. Mimo, że wzrost jest liniowy, to nie można wykluczyć, że któryś z algorytmów dla jeszcze większych plików zmieni swoje zachowanie.

- Zestawienie końcowe:

Tab. 7. Przedstawiająca krótkie zestawienie najlepszych algorytmów dla dwóch grup walidacji.

Kryterium	Walidacji w trakcie wczytywania pliku	Walidacji po wczytaniu pliku
Najkrótszy czas przetwarzania	*BufferedReader/Files.lines*	*BufferedReader/Files.lines*
Najminiejsze zużycie pamięci	*FileReader/CSVReader*	*BufferedReader/Files.lines*
Najdłuższy czas przetwarzania	*CSVReader/Scanner*	*CSVReader*
Największe zużycie pamięci	*Scanner*	*CSVReader*

4. Podsumowanie

W pracy przedstawiono problem efektywnego wczytywania dużych plików *CSV* o zróżnicowanej strukturze.

Opisano problem oraz podano rozwiązania służące do przeprowadzenia testów. Algorytmy jakie zostały użyte to:

- *BufferedReader*,
- *CSVReader*,
- *FileReader*,
- *Files.lines*,
- *Scanner*.

Przedstawiono dwie koncepcje na przeprowadzenie walidacji:

- Walidacja uruchomiona podczas wczytywania pliku *CSV* do programu.
- Walidacja uruchomiona po załadowaniu całego pliku *CSV* do programu.

Postawiono następujące pytania badawcze:

1. Jaki jest najszybszy sposób na wczytanie i przetwarzanie dużych plików *CSV* spośród testowanych algorytmów?
2. Jaki sposób wczytanie i przetwarzanie dużych plików *CSV* zużywa najmniej pamięci spośród testowanych algorytmów?
3. Czy moment wykonywania walidacji wpływa na czas oraz pamięć potrzebną do wykonania zadania?

Przeprowadzono badania, zebrane w ten sposób wyniki zostały uwiarygodnione statystycznie. Wyniki przedstawiają się następująco:

1. Najszybszymi sposobami na wczytywanie i walidowanie plików w formacie *CSV* są algorytmy *BufferedReader* oraz *Files.lines*().
2. Algorytmem zużywającym najmniej pamięci w trakcie działania był *FileReader*.
3. Porównanie walidacji przeprowadzanej w trakcie wczytywania było szybsze niż

podejście, gdy walidacja następowała po zakończeniu wczytywania pliku do pamięci programu.

Użyteczność algorytmów została oceniona następująco:

1. *BufferedReader* oraz *FilesLines* – najlepsza wydajność, średnia konsumpcja pamięci, brak udogodnień do pracy z plikami *CSV*.
2. *CSVReader* – słaba wydajność, bardzo łatwe pisanie kodu obsługi plików CSV, dzięki rozbudowanej funkcjonalności biblioteki.
3. *FileReader* – średnia wydajność czasowa, dobra wydajność pamięciowa, zdecydowanie najtrudniejsza do zaimplementowania, brak gotowych rozwiązań.
4. *Scanner* – słaba wydajność, duży apetyt na pamięć, mały plus za możliwość używania tokenów o konkretnych typach.

5. Bibliografia

1. Bloch J., *Effective Java*, Addison Wesley, 2018.
2. Evans B. J., Clark J., Flanagan D., *Java in a Nutshell*, O'Reilly Media, Sebastopol 2019.
3. Iwankowski P., *Test ANOVA*. https://pogotowiestatystyczne.pl/slowniki/anova/.
4. Iwankowski P., *Test Levene'a*. https://pogotowiestatystyczne.pl/slowniki/test-levenea/.
5. Iwankowski P., *Test Kruskala-Wallisa*. https://pogotowiestatystyczne.pl/slowniki/test-kruskala-wallisa/.
6. Iwankowski P., *Test Shapiro-Wilka*. https://pogotowiestatystyczne.pl/slowniki/test-shapiro-wilka/.
7. *Java FileReader Class*, 2025, https://www.geeksforgeeks.org/java/java-io-filereader-class/.
8. Jenkov J., *Java BufferedReader*, https://jenkov.com/tutorials/java-io/bufferedreader.html.
9. Jenkov J., *Java FileReader*, 2021, https://jenkov.com/tutorials/java-io/filereader.html.
10. Kumar P., *Scanner Class in Java*, https://www.digitalocean.com/community/tutorials/scanner-class-in-java.
11. Morelli R., Walde R. *Java, Java, Java Object-Oriented Problem Solving*, Trinity College, Hartford 2017.
12. Opencsv, *Class CSVReader*, https://opencsv.sourceforge.net/apidocs/com/opencsv/CSVReader.html#hasNext.
13. Opencsv, *Opencsv Users Guide*, 2025, https://opencsv.sourceforge.net/.
14. Oracle, *Class BufferedReader*, https://docs.oracle.com/en/java/javase/24/docs/api/java.base/java/io/BufferedReader.html.
15. Oracle, *Class BufferedReader*, https://docs.oracle.com/javase/8/docs/api/?java/io/BufferedReader.html.
16. Oracle, *Class Files*, https://docs.oracle.com/en/java/javase/24/docs/api/java.base/java/nio/file/Files.html.
17. Oracle, *Class InputStreamReader*, https://docs.oracle.com/javase/8/docs/api/java/io/Reader.html#read--.
18. Oracle, *Class Scanner*, https://docs.oracle.com/javase/8/docs/api/java/util/Scanner.html.
19. Oracle, *Interface AutoCloseable*, https://docs.oracle.com/javase/8/docs/api/java/lang/AutoCloseable.html.
20. *Reading a CSV file in Java using OpenCSV*, 2025, https://www.geeksforgeeks.org/java/reading-csv-file-java-using-opencsv/.

21. Ramgir M. i Samoylov N., *Java 9 High Performance,* Packt, Birmingham 2017.
22. Sanecki C., *Klasy Utility - zwykłe lenistwo czy zło konieczne?*, 2021, https://cezarysanecki.pl/2021/02/17/klasy-utility-zwykle-lenistwo-czy-zlo-konieczne/
23. Sierra K. i Bates B., *Java. Rusz głową!*, tł. P. Rajca, Helion, Gliwice 2011.
24. Sztos IT, *Post Hoc Tukeya*, https://sztos-it.com/wzory_statystyczne_analiza_post_hoc_tukeya.html**.**
25. *Testy nieparametryczne*, 2014. https://manuals.pqstat.pl/statpqpl:porown3grpl:nparpl**.**
26.
27. W3Schools, *Java Scanner close() Method*, https://www.w3schools.com/java/ref_scanner_close.asp.
28. W3Schools, *Java Scanner Methods*, https://www.w3schools.com/java/java_ref_scanner.asp.

6. Spis table i rysunków